České vysoké učení technické v Praze
Fakulta jaderná a fyzikálně inženýrská

Katedra softwarového inženýrství
Obor: Aplikace softwarového inženýrství

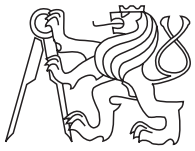

Porovnání účinnosti komprese dat ve formátech XML a JSON

Comparison of the effectiveness of data compression in XML and JSON format

DIPLOMOVÁ PRÁCE

Vypracoval: Bc. Tomáš Smola
Vedoucí práce: Ing. Tomáš Liška, Ph.D.
Rok: 2015

Před svázáním místo téhle stránky vložte zadání práce s podpisem děkana (bude to jediný oboustranný list ve Vaší práci) !!!!

Prohlášení

Prohlašuji, že jsem svou diplomovou práci vypracoval samostatně a použil jsem pouze podklady (literaturu, projekty, SW atd.) uvedené v přiloženém seznamu.

V Praze dne .....

.....
Bc. Tomáš Smola

Poděkování

Děkuji Ing. Tomáši Liškovi, Ph.D. za vedení mé diplomové práce a za podnětné návrhy, které ji obohatily.

Bc. Tomáš Smola

Název práce:
Porovnání účinnosti komprese dat ve formátech XML a JSON

Autor: Bc. Tomáš Smola

Obor: Aplikace softwarového inženýrství
Druh práce: Diplomová práce

Vedoucí práce: Ing. Tomáš Liška, Ph.D.
Katedra softwarového inženýrství, Fakulta jaderná a fyzikálně inženýrská, České vysoké učení technické v Praze
Konzultant: —

Abstrakt: Cílem práce je porovnání přínosu znalosti struktury dat při kompresi souborů formátu XML a JSON proti klasickým algoritmům a také vzájemné porovnání vhodnosti obou formátů ke kompresi.
V teoretické části práce je provedena důkladná analýza formátů XML a JSON, na kterou navazuje popis vybraných existujících kompresních algoritmů a to jak obecných, tak i specializovaných na XML a JSON.
Praktická část popisuje vytvořenou knihovnu vybraných kompresních algoritmů a algoritmy samotné. Navíc jsou zde popsány i úskalí, se kterými je potřeba se při návrhu a implementaci vypořádat. Hlavním výstupem práce je otestování vlastních i existujících algoritmů na testovacích datech a srovnání dosažených výsledků.

Klíčová slova: XML, JSON, komprese dat, C#

Title:
Comparison of the effectiveness of data compression in XML and JSON format

Author: Bc. Tomáš Smola

Abstract: The aim of this thesis is to compare the benefits of the knowledge of data structure of XML and JSON when compressing files against classical algorithms, as well as the appropriateness of the mutual comparison of the two formats for compression.
In the theoretical part there is a thorough analysis of formats XML and JSON, which is followed by a description of selected existing compression algorithms both genereal and specialized in XML and JSON.
The practical part describes created library of selected compression algorithms and the algorithms themselves. Additionally, there are also described difficulties which it is necessary to deal with for the design and implementation. The main outcome of this thesis is to test self-implemented and existing algorithms on test data and comparison of results.

Key words: XMK, JSON, data compression, C#

Obsah

Úvod

Závěrečnou diplomovou práci ke studijnímu oboru Aplikace softwarového inženýrství s názvem Porovnání účinnosti komprese dat ve formátu XML a JSON jsem si vybral z důvodu aktuálnosti, XML a JSON jsou v současnosti jedny z nejpoužívanější textových datových formátů, a také proto, že toto téma velmi dobře propojuje teoretické znalosti získané při studiu s praktickými zkušenostmi v oboru softwarového inženýrství.

Dle výzkumu International Data Corporation (IDC) The Digital Universe of Opportunities: Rich Data and the Increasing Value of the Internet of Things [9] bylo pouze v roce 2014 vytvořeno a zkonzumovýno 2837 EB (exabytů) dat. Ze závěrů vyplývá, že se toto číslo každé dva roky zdvojnásobí, tedy v roce 2020 to bude již přibližně 40000 EB. Takové množství dat klade enormní požadavky na přenosové kanály a datová úložiště. Jako příklad mohou sloužit miliony shlédnutí oblíbených videí na serveru youtube.com. Pouze jedna sekunda videa v nekomprimovaném formátu CCIR 601 zabere více než 20 MB, tímto způsobem by zmiňovaná služba nemohla fungovat.

Vzhledem k tomu, že jsou technologie omezeny současnými možnostmi, znalostmi a také fyzikálními limity, je nutné hledat řešení jinde než v jejich zlepšování. Zde přichází na řadu komprese dat jako účinná metoda snížení velikosti objemu přenášených a ukládaných dat. Ve své práci bych čtenáře rád seznámil se základními principy komprese a vybranými kompresními algoritmy. Hlavním cílem je ale zodpovědět otázku, zda je možné dosáhnout dalších úspor volbou XML nebo JSON formátu a vhodného algoritmu, který využije znalosti struktury datového formátu.

Tato práce soustřeďující se na využití znalosti struktury dat při kompresi se skládá celkem z 8 kapitol. Postupně jsou čtenáři představeny porovnávané datové formáty XML a JSON, základní techniky komprese, existující kompresní algoritmy, mnou implementované algoritmy a na závěr porovnání vybraných algoritmů na testovacích datech.

První kapitola otevírá teoretickou část práce a popisuje porovnávané formáty a to jak z pohledu důvodů vzniku a použitelnosti, tak i z pohledu syntaktické analýzy. Zápis dat pomocí obou formátů je znázorněn na krátkých příkladech. Tyto znalosti jsou stěžejní pro praktickou část práce.

Druhá, třetí a čtvrtá kapitola jsou věnovány základním pojmům kompresního procesu a vybraným technikám bezeztrátové komprese. Pomocí příkladů jsou zde čtenáři názorně vysvětleny na příkladech způsoby přístupu ke kompresi známých algoritmů.

V kapitolách 5 a 6 jsou představeny algoritmy využívající znalosti struktury dat v XML a JSON. Důraz je kladen především na popis využití této znalosti a způsobu zpracování dat. Tímto je uzavřena teoretická část práce a získané poznatky jsou aplikovány v části praktické.

Praktická část se skládá ze dvou kapitol. V první popisuji způsob implementace vybraných kompresních algoritmů, který by měl vnést hlubší pohled do problematiky a odkrýt potenciální slabá místa. Poslední kapitola je věnována vzájemnému porovnání účinnosti komprese na data ve formátech XML a JSON. Hodnoty naměřené při testování jsou zobrazeny v přehledných grafech s vysvětlením příčin, které k tomuto výsledku mohly vést.

V závěru práce jsou na základě naměřených hodnot shrnuty a vyhodnoceny poznatky o účinnosti komprese využívající znalosti struktury datového formátu.

Kapitola 1

Obecné seznámení s formáty XML a JSON

V této kapitole seznámím čtenáře se značkovacím jazykem XML a následně s JSON, formátem pro výměnu dat. Mým cílem je popsat základní charakteristiky a syntaxi obou formátů tak, abych byl já, a následně i čtenář, schopen pochopit v kapitolách 5 a 6 principy a výhody vybraných algoritmů využívajících znalosti struktury dat.

1.1 XML

Na základě značkovacího jazyka SGML (Standard Generalized Markup Language), jehož obecnost činí úplnou implementaci náročnou, vznikl vybráním nejpoužívanějších možností značkovací jazyk XML (eXtensible Markup Language), je tedy podmnožinou jazyka SGML. XML je obecný a otevřený, jeho vývoj a standardizaci realizovalo konsorcium W3C (World Wide Web Consorcium) [12]. XML umožňuje snadné vytváření konkrétních značkovacích jazyků pro popis dokumentů a dat ve standardizované, textově orientované podobě.

1.1.1 Charakteristika

V podstatě jde o textový dokument, jenž je tvořen posloupností Unicode[1] znaků, ve kterém se rozlišují dvě základní součásti: elementy (značky) a obsah. Strukturu zapisovaných dat je možné vystihnout vzájemným vnořováním jednotlivých značek, které se ale nesmí křížit. XML je pro člověka čitelný jazyk a spousta dnešních aplikací (například internetových prohlížečů) podporou zobrazení a vhodným formátováním tuto čitelnost ještě zvyšuje.

Jazyk XML se využívá hlavně pro publikování dokumentů, při výměně dat mezi různými systémy v prostředí internetu, jako univerzální úložiště dat či jako konfigurační soubor. Obecně lze říci, že je vhodný pro strukturovaná data. Do dokumentu můžeme vložit libovolná data, jejichž význam není bez použití schématu dokumentu zřejmý. Abychom mohli definovat sadu elementů (viz následující část 1.1.2), případně v nich i kontrolovat typ dat, definujeme schéma dokumentu, které je vloženo buď přímo, nebo formou odkazu na definiční dokument.

[1] Unicode je standard pro konzistentní kódování, reprezentaci a manipulaci znaků většiny světových abeced.

1.1.2 Syntaktická analýza

Jak bylo řečeno již dříve, základními kameny XML jsou elementy a jejich obsah. Při práci s XML je nutné mít na paměti, že je na dodržení syntaxe kladen velmi velký důraz. Při dodržení správného způsobu zápisu a pravidel, která budou popsána níže, lze dokument považovat za tzv. well-formed XML [12].

Element

Základním prvkem každého XML dokumentu je element, který je vyznačen pomocí takzvaných tagů[2], mezi které může být vložen obsah. Počáteční i ukončující tag je dle definice [12] složen z dvojice znamének `<` (menší než) a `>` (větší než), mezi kterými je zapsán název tagu a volitelně i atributy. Ukončovací tag má navíc před svým názvem znak `/` (lomeno). Při správné aplikaci pravidel může vypadat element například následujícím způsobem:

`<název_elementu název_atributu="hodnota atributu"></název_elementu>`.

V případě, že element neobsahuje žádný obsah, lze ho zkráceně zapsat jako tzv. prázdný element:

`<název_prázdného_elementu />`.

V případě nedodržení správné syntaxe může nastat problém při rozpoznávání zapsaných dat, což může mít za následek nekompatibilitu mezi různými systémy při výměně dat.

Atribut

Počáteční tag elementu může obsahovat atributy upřesňující jeho význam. Atribut je vždy složen ze svého názvu a hodnoty, které jsou odděleny znakem `=` (rovná se). Hodnota je navíc zapsána mezi dvojici znaků `"` (uvozovky) nebo `'` (apostrof), přičemž hodnota může obsahovat jeden z těchto znaků tak, že se syntakticky nekříží. Následuje příklad atributu, jehož hodnota obsahuje znak `'`:

`název_atributu="hodnota atributu osahující znak ' (apostrof)"`.

Obsah

Vše, co není tagem, je v dokumentu považováno za obsah. Kromě obyčejného textu mohou být obsahem další vnořené elementy, komentáře, instrukce pro zpracování, reference a další. Vzhledem k tomu, že určité znaky mají v syntaxi XML speciální význam (např. `<`, `>`), využívají se pro jejich zápis znakové entity[3]. Úplný výčet toho, co může XML dokument obsahovat, je včetně pravidel definován v [12].

1.1.3 Vzorový příklad

Na následujících řádcích je zapsán XML element typu `Person`, oblíbená postavička Homer Simpson ze seriálu The Simpsons, který kromě jiného obsahuje vnořený element typu `Relatives`, který zde slouží jako kontejner s Homerovými příbuznými.

[2] Tag definuje formu části textu.

[3] Pomocí znakových entit (sekvence znaků) lze zapsat znaky, které neobsahuje zvolená znaková sada, nebo mají v použitém kontextu speciální význam.

```
<Person>
    <FirstName>Homer</FirstName>
    <LastName>Simpson</LastName>
    <Relatives>
        <Relative>Grandpa</Relative>
        <Relative>Marge</Relative>
        <Relative>Bart</Relative>
        <Relative>Lisa</Relative>
        <Relative>Maggie</Relative>
    </Relatives>
</Person>
```

1.2 JSON

JSON neboli JavaScript Object Notation je odlehčený způsob zápisu (formátování) dat. Navzdory svému názvu jde o datově orientovaný textový formát nezávislý na počítačové platformě a čitelný pro člověka. Vznikl jako alternativa ke XML v oblasti výměny dat mezi systémy bez ohledu na použité technologie.

1.2.1 Charakteristika

Jak již název napovídá, je JSON velice úzce spojen s programovacím jazykem JavaScript – z jeho syntaxe byl odvozen a je z velké části podmnožinou toho jazyka. Hlavními prvky JSON jsou dvě univerzální datové struktury: kolekce dvojic klíč/hodnota s unikátními klíči (tzv. associative array) a seřazený seznam hodnot (tzv. array), které podporují v nějaké formě asi všechny známé moderní programovací jazyky.

Silnou stránkou JSON je rychlost zpracování JavaScriptem, bohužel právě přímé zpracování je zároveň potenciální hrozbou, neboť může být zneužito útočníkem k vykonání nějakého škodlivého kódu.

Orientace na data a zvolená syntaktická struktura umožňují přehledný zápis datových objektů. Protože co jiného než popis atributů (asociativní pole) a výčet hodnot (pole) datové objekty obsahují.

1.2.2 Syntaktická analýza

Dle definice [8] je JSON posloupností tokenů tvořených z Unicode znaků. Sada tokenů obsahuje šest strukturálních tokenů: `[` (levá hranatá závorka), { (levá složená závorka), `]` (pravá hranatá závorka), } (pravá složená závorka), `:` (dvojtečka) a `,` (čárka); dále obsahuje znakové řetězce, čísla a tři doslovné tokeny: `true`, `false` a `null`. Na obrázcích 1.1 až 1.5 lze vidět schémata, která popisují syntaxi formátu. Čteme je zleva doprava a tam, kde to schéma dovoluje, se můžeme i vracet. Všechny znaky, hodnoty atd., na které při procházení narazíme, může zkoumaný prvek v daném pořadí obsahovat.

Hodnoty

Za hodnotu je v JSON považován objekt, pole, číslo, řetězec, `true`, `false`, nebo `null`.

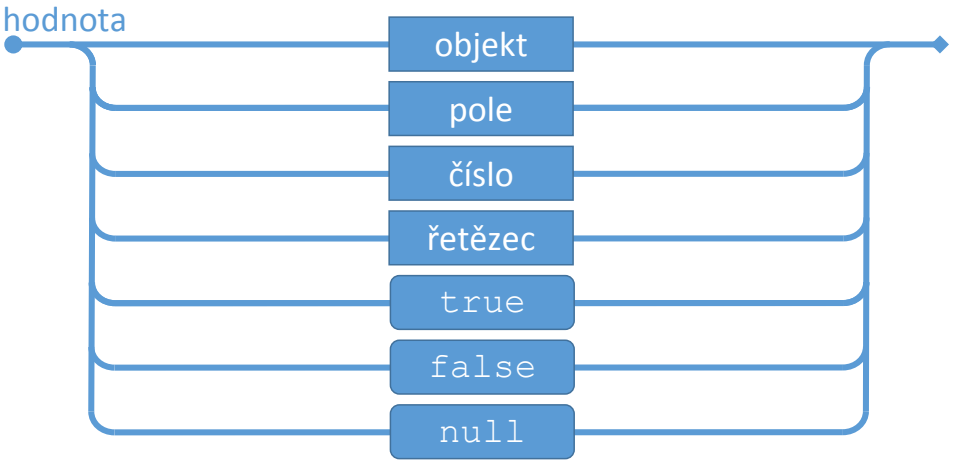

Obrázek 1.1: Struktura hodnoty

Objekty

Objekt je reprezentován dvojicí složených závorek, uvnitř kterých je žádná nebo více dvojic klíč/hodnota, přičemž klíč je řetězec. Klíč a hodnota jsou odděleny dvojtečkou a jednotlivé dvojice odděluje čárka.

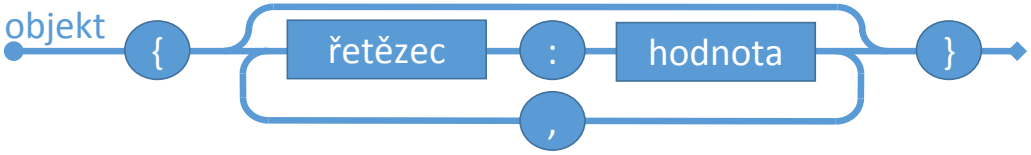

Obrázek 1.2: Struktura objektu

Pole

Pole je složeno z dvojice hranatých závorek, mezi kterými může být nula nebo více seřazených hodnot, které jsou odděleny čárkou.

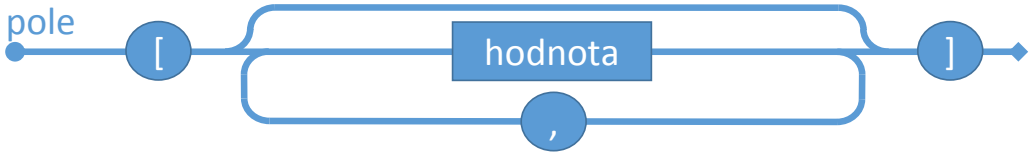

Obrázek 1.3: Struktura pole

Čísla

Čísla jsou v desítkové soustavě (tedy číslice $0-9$), záporná čísla jsou uvozena znaménkem `-` (mínus), desetinná část je oddělena znaménkem `.` (tečka). Je možný i takzvaný vědecký zápis čísel s použitím symbolů `e` (malé e) nebo `E` (velké e) a volitelně lze použít u exponentu znaménka `+` (plus) nebo `-` (mínus).

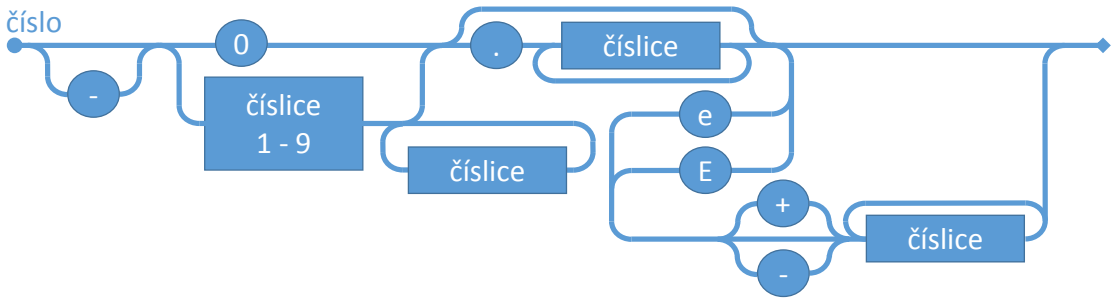

Obrázek 1.4: Struktura čísla

Řetězce

Řetězec je posloupnost Unicode znaků uvozená a zakončená znakem `"` (uvozovky). Mezi uvozovky mohou být zapsány všechny znaky kromě speciálních znaků, které jsou uvozeny tzv. únikovým znakem \ (zpětné lomítko), těmito znaky jsou například `"`, \, `t` (znak tabulátoru), `n` (znak posunu kurzoru na nový řádek) a `r` (znak posunu kurzoru na začátek řádku, známý jako návrat vozíku) a další. Kompletní výčet je možné vidět na obrázku 1.5 nebo v [8]. Navíc je možné každý znak zapsat pomocí kombinace `\u` a čtyřmístného hexadecimálního čísla odpovídajícího Unicode kódu požadovaného znaku. Řetězec obsahující pouze zpětné lomítko můžeme tedy zapsat následujícími způsoby: `"\\"`, `"\u005c"` nebo `"\u005C"` (u hexadecimálních čísel `A-F` nezáleží na velikosti).

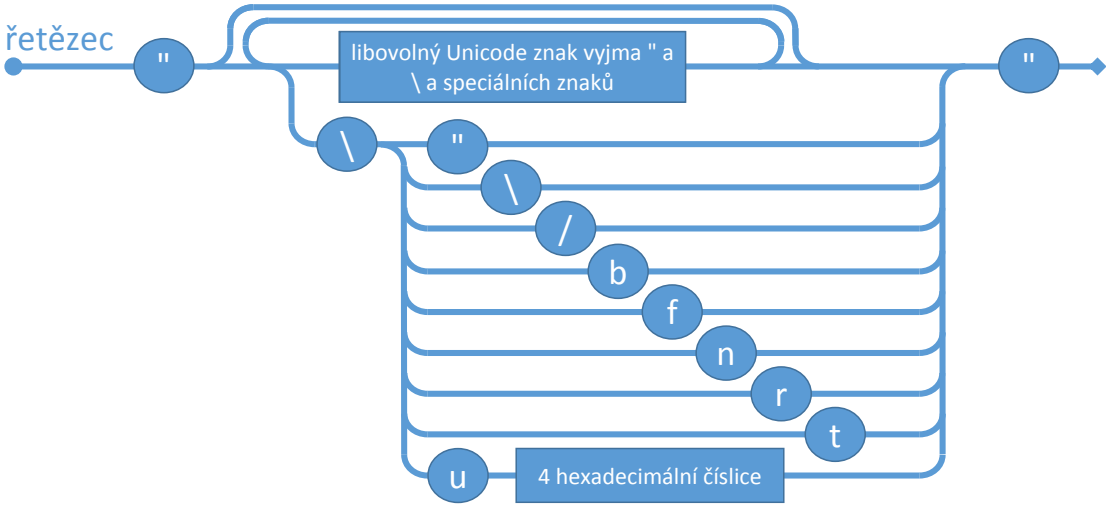

Obrázek 1.5: Struktura řetězce

1.2.3 Vzorový příklad

Stejně jako ve vzorovém příkladu 1.1.3 ke XML, je zde popsána postavička Homera Simpsona včetně příbuzných, tentokrát ale v notaci JSON. Jde o objekt složený ze tří atributů, první dva mají hodnoty typu řetězec, k poslednímu `relatives` ale přísluší hodnota typu pole, ve kterém je vloženo pět příbuzných – hodnot typu řetězec.

```
{
    "firstName": "Homer",
    "lastName": "Simpson",
    "relatives": [
        "Grandpa",
        "Marge",
        "Bart",
        "Lisa",
        "Maggie"
    ]
}
```

1.3 Vzájemné porovnání XML a JSON

Je XML obecně lepší než JSON? Co vlastně dělá jeden formát lepší než jiný? Na toto bylo vedeno již nespočet diskusí. Argumentace obou stran diskuse je obvykle podložena jak teoretickou znalostí formátů, tak i praktickým použitím v reálných projektech. I přesto si myslím, že žádná diskuse nepřinesla jednoznačnou odpověď na výše položenou otázku, což samozřejmě pro některé konkrétní případy použití neplatí a volba jednoho z formátů je nutná nebo alespoň výhodnější. Ze svého zkoumání této problematiky si ale odnáším jeden závěr – vždy záleží na konkrétní situaci. Před samotným rozhodnutím, který z formátů využít, je vhodné zvážit důležité požadavky a do těchto úvah zahrnout klidně i další z existujících datových formátů. Zároveň lze ale říci, že pokud splňuje vybraný formát požadavky, tak ho lze považovat za dostatečný

Podíváme-li se znovu na vzorové příklady zápisu dat nebo položíme-li si vedle sebe stejná data zapsaná do obou formátů (viz příloha A.1), můžeme lehce vidět vzájemnou podobnost. Ve své práci proto vycházím z předpokladu, že jsou oba formáty z hlediska toho, jaká data lze do nich zapsat, ekvivalentní. Respektive budu pro další porovnání používat pouze takový druh dat, který bude tento předpoklad splňovat.

Kapitola 2

Komprese dat

Komprese nebo také komprimace dat je taková transformace dat, která má za cíl úsporu zdrojů při archivaci dat anebo snížení datového toku při přenosu, to vše při současném zachování informace obsažené v datech. Jinými slovy jde o redukci velikosti datových souborů, jehož následkem je úspora paměťových či přenosových kapacit. Postup, při kterém z komprimovaných dat rekonstruujeme data originální, se nazývá dekomprese.

2.1 Princip komprese dat

Data velmi často obsahují tzv. redundantní[1] informaci, toho právě využívá komprese – data jsou zpracována tak, aby byla redundance minimalizována. Jak lze vidět na obrázku 2.1, je na vstupní data použita operace komprese. Operací dekomprese dostaneme poté data rekonstruovaná – v závislosti na použité kompresní metodě a požadavcích získáme buď data přesně odpovídající původním, nebo pouze částečná. Z tohoto hlediska rozlišujeme dva typy kompresních metod: ztrátové a bezeztrátové.

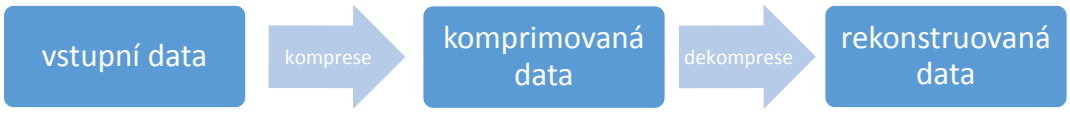

Obrázek 2.1: Princip komprese

2.2 Typy kompresních metod

Jak název napovídá, při ztrátové kompresi ztratíme část informace obsaženou v původních datech, respektive jsou původní data pouze aproximována. Toto nám nemusí vadit například u obrázků, zvuku a videí, kde je využito nedokonalosti lidských smyslů. Lidské ucho nedokáže například slyšet velmi vysoké frekvence. Má smysl v datech určených k poslechu zachovávat informaci, kterou nemůže člověk slyšet? Častá odpověď je „ne“. Tohoto principu využívá mnoho kompresních metod, například známý zvukový formát MP3. Odstraněním nepotřebné informace z dat je dosaženo ještě větší redukce objemu.

[1] Redundance znamená informační nadbytek, např. vícenásobný výskyt slov v textu.

Naopak v případě bezeztrátových metod je při kompresi zachována veškerá informace a při dekompresi jsou rekonstruována původní data. Těchto metod se využívá převážně tam, kde není možné původní data jakkoliv pozměnit. Například data ve formátech XML a JSON, kterým se věnuji v této práci, si nemůžeme dovolit pozměnit (přestanou mít původní význam), nebo dokonce ztratit.

2.3 Charakteristika komprese

Kompresní algoritmy lze hodnotit z mnoha různých úhlů pohledu. Můžeme měřit složitost algoritmu, rychlost, jakou jsou data komprimována a dekomprimována (to může být ovlivněno výkonem stroje, na kterém algoritmus běží), jak moc odpovídají rekonstruovaná data původním atd. Jednou z nejčastějších charakteristik je, logicky ze smyslu komprese vyplývající, tzv. kompresní poměr, který vyjadřuje velikost komprimovaných dat vůči původním, lze ho zapsat následujícím vztahem:

$$\texttt{kompresní poměr} = \frac{\texttt{délka původních dat}}{\texttt{délka komprimovaných dat}}. \tag{2.1}$$

Další sledovanou charakteristikou je tzv. úspora místa, která je vyjádřena jako:

$$\texttt{úspora místa} = \texttt{1 - kompresní poměr}^{-1}. \tag{2.2}$$

Mějme například 2D obrázek o velikosti 256×256 pixelů, který zabírá 65536 bytů. Obrázek zkomprimujeme a zabírá-li komprimovaná verze 16384 bytů, můžeme říct, že kompresní poměr je $4 : 1$ a úspora místa 75 %.

2.4 Míra informace v datech

Než se budeme moci věnovat jednotlivým kompresním metodám, připomeňme stručně myšlenky z teorie informace, které poskytly základ pro rozvoj metod bezeztrátové komprese. V této části předpokládám čtenářovu znalost základů teorie pravděpodobnosti a statistiky.

Informační entropie[2], jakožto míra neurčitosti v datech, nám pomůže lépe porozumět principům komprese. Představme si dva zdroje (označím je $\mathbf{Z}_1$ a $\mathbf{Z}_2$), které produkují zprávy složené ze symbolů (znaků) zdrojové abecedy $\mathbb{A} = \{\alpha, \beta, \gamma, \delta\}$. Oba zdroje generují znaky zprávy náhodně, pro zdroj $\mathbf{Z}_1$ však platí, že mají všechny znaky stejnou pravděpodobnost výskytu a to 0,25. Pro zdroj $\mathbf{Z}_2$ jsou pravděpodobnosti výskytu popsány v tabulce 2.1. Který ze zdrojů produkuje více informace?

Znak	Pravděpodobnost výskytu
α	$p_\alpha = 0,5$
β	$p_\beta = 0,3$
γ	$p_\gamma = 0,1$
δ	$p_\delta = 0,1$

Tabulka 2.1: Pravděpodobnost výskytu znaků abecedy $\mathbb{A}$ ve zdroji $\mathbf{Z}_2$

[2]Nazývaná též Shannonova po Claudu E. Shannonovi, který zformuloval klíčové poznatky.

Claude E. Shannon si tuto otázku položil následujícím způsobem. Jaký je nejmenší počet otázek s odpověďmi ano nebo ne, které musíme zodpovědět, abychom byli schopni rozhodnout, jaký je následující znak každého zdroje? Odpovědí na tuto zdánlivě složitou otázku je vyhledávací algoritmus binární vyhledávání. Nejefektivnějším způsobem je v každém kroku položit takovou otázku, která rozdělí prohledávaný interval na dvě poloviny z hlediska pravděpodobnosti. Pro zobrazení, jaké otázky pokládat a v jakém pořadí, můžeme využít binární rozhodovací stromy (viz obrázky 2.2 pro zdroj $\mathbf{Z}_1$ a 2.3 pro zdroj $\mathbf{Z}_2$). Čteme je zleva doprava, v uzlech jsou otázky, hrany odpovídají odpovědím a v listech jsou příslušné znaky.

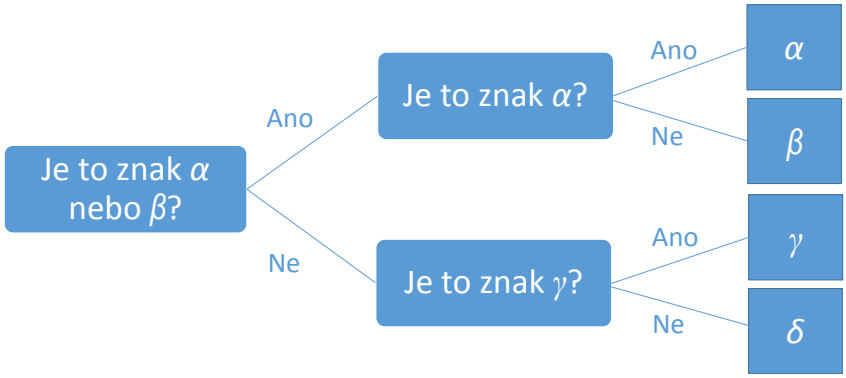

Obrázek 2.2: Binární rozhodovací strom pro zdroj $\mathbf{Z}_1$

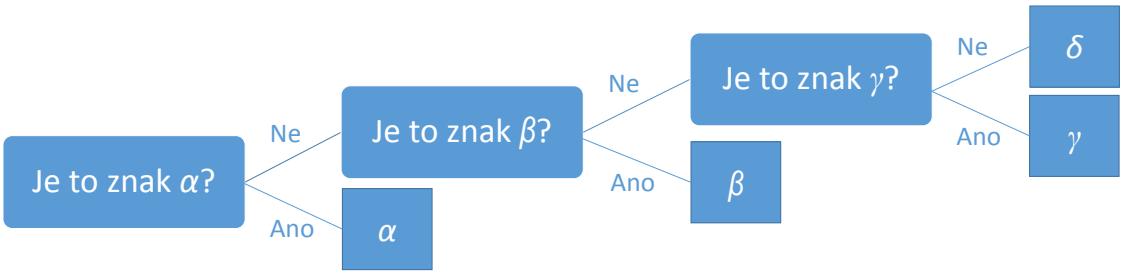

Obrázek 2.3: Binární rozhodovací strom pro zdroj $\mathbf{Z}_2$

Průměrný počet otázek na zjištění jednoho znaku (tento počet označím $\bar{q}$) pokládaných tímto způsobem odpovídá pravděpodobnostem výskytu jednotlivých znaků a lze jej vypočítat jako $\bar{q} = \sum_{a \in \mathbb{A}} \#a \cdot p_a$, kde $\#a$ je počet otázek pro zjištění, že jde o znak a, a p_a je pravděpodobnost výskytu znaku a. Pro zdroj $\mathbf{Z}_1$ dostaneme $\bar{q}_1 = 2p_\alpha + 2p_\beta + 2p_\gamma + 2p_\delta = 2 \cdot 0,25 + 2 \cdot 0,25 + 2 \cdot 0,25 + 2 \cdot 0,25 = 2$, tedy 2 otázky na znak, a pro zdroj $\mathbf{Z}_2$ dostaneme podobně $\bar{q}_2 = 1p_\alpha + 2p_\beta + 3p_\gamma + 3p_\delta = 1 \cdot 0,5 + 2 \cdot 0,3 + 3 \cdot 0,1 + 3 \cdot 0,1 = 1,7$, tedy 1,7 otázky na znak.

To znamená, že budeme-li se ptát na 1000 znaků u obou zdrojů, budeme muset položit 2000 otázek ke zjištění znaků ze zdroje $\mathbf{Z}_1$ a 1700 otázek ke zjištění znaků ze zdroje $\mathbf{Z}_2$. Výstup zdroje $\mathbf{Z}_2$ obsahuje méně překvapení, nebo lépe neurčitosti, než výstup zdroje $\mathbf{Z}_1$. Hovoříme o tom, že výstup zdroje $\mathbf{Z}_2$ poskytuje méně informace než výstup zdroje $\mathbf{Z}_1$.

2.4.1 Entropie informačního zdroje

V Shannonově teorii je definice zdroje informace prakticky totožná s definicí pravděpodobnostního prostoru, tj. trojice $(\mathcal{X}, \mathcal{S}, p)$, kde $\mathcal{X}$ je množina elementárních jevů (zpráv), $\mathcal{S}$ je třída náhodných jevů (σ-algebra podmnožin $\mathcal{X}$) a p je pravděpodobnostní míra na $\mathcal{S}$. [11]

Pro nás bude modelem zdroje informace diskrétní pravděpodobnostní prostor $(\mathcal{X}, p(x))$, který generuje zprávu X, jež je náhodnou veličinou s výběrovým prostorem $(\mathcal{X}, px(x))$. Mezi zprávou X a zdrojem $(\mathcal{X}, p(x))$ panuje ekvivalence, značíme $X \sim (\mathcal{X}, p(x))$. Základním pojmem teorie informace je entropie $H(X)$ zdroje X, jde o číslo, kterým charakterizujeme, jak obtížné je předpovědět hodnotu dané náhodné veličiny X, tj. zprávu, kterou vyprodukuje daný zdroj informace $X \sim (\mathcal{X}, p(x))$. Následuje formální definice entropie. [11]

Definice 2.1. *Entropie zdroje informace $X \sim (\mathcal{X}, p(x))$ je veličina*

$$H(X) = -\sum_{x \in \mathcal{X}} p(x) \log p(x),$$

kde $0 \log 0 = \lim_{t \to 0_+} t \log t = 0$.

2.4.2 Entropie a komprese

Když chceme komprimovat digitální data, musíme je rozdělit na malé kousky, např. obrázek na pixely, textová data na znaky. To nám umožní zpracovat tato data jako posloupnost symbolů. Jednotlivé symboly pak můžeme reprezentovat s použitím nějakého kódu. Umíme-li zprávy vysílat a přijímat pouze v binární soustavě, vytvoříme kód[3] složený ze znaků kódové abecedy $\mathbb{B} = \{0, 1\}$.

Vraťme se nyní zpět k abecedě $\mathbb{A}$ a představme si zdroj $\mathbf{Z}$, který generuje zprávy složené ze znaků abecedy $\mathbb{A}$. Tento zdroj má pravděpodobnosti výskytu jednotlivých znaků odpovídající zdroji $\mathbf{Z}_2$, což my zatím ale nevíme. Jako příklad můžeme mít za úkol komprimovat text obsahující 1000 znaků vygenerovaných zdrojem $\mathbf{Z}$. V takovém případě intuitivně přiřadíme jednotlivým zdrojovým znakům nejkratší možná kódová slova viz kód κ_1 v tabulce 2.2. Tato slova mají délku 2, což znamená, že potřebujeme průměrně 2 bity na znak.

Zdrojový znak	Kódové slovo
α	11
β	10
γ	01
δ	00

Tabulka 2.2: Kód κ_1 pro zdroj $\mathbf{Z}_1$

Pokud analýzou zdroje $\mathbf{Z}$ ale zjistíme, že pravděpodobnosti výskytu odpovídají zdroji $\mathbf{Z}_2$ (viz tabulka 2.1), můžeme znakům přiřadit jiná kódová slova (viz tabulka 2.3), která budou brát ohled na nové pravděpodobnosti výskytu. Tento kód κ_2 je tzv. Huffmanův kód (viz kapitola 3 v [5]) a potřebuje průměrně 1,7 bitu na znak, způsob jeho vytvoření je popsán v části 3.2 nebo v [5].

[3] Takové binární kódy provází lidstvo již velice dlouho, např. kouřové signály, kódování znaků v Morseově abecedě.

Zdrojový znak	Kódové slovo
α	1
β	01
γ	000
δ	001

Tabulka 2.3: Kód κ_2 pro zdroj $\mathbf{Z}_2$

Podíváme-li se na obrázky 2.2 a 2.3 a příslušný výpočet průměrného počtu otázek na zjištění znaku, můžeme vidět jisté souvislosti. Například když slova Ano/Ne na hranách rozhodovacího stromu nahradíme čísly 1, resp. 0, dostaneme čtením od kořene k listům odpovídající kódová slova. Stejně tak průměrný počet otázek na zjištění znaku odpovídá střední délce zvoleného kódování (viz definice 7 v [5]).

K jaké úspoře dojde? K zakódování 1000 znaků výše zmíněného textu pomocí kódu κ_1 potřebujeme 2000 bitů, ale při použití kódu κ_2 nám bude stačit pouze 1700 bitů. Úspora je tedy 300 bitů. Na otázku, zda je možné tuto úsporu ještě zvýšit, nelze odpovědět jenom ano nebo ne. Pokud zkrátíme délku některých kódových slov v kódu κ_2, stane se zakódovaná zpráva dvojznačnou a zpětně nedekódovatelnou. Kódujme například znak δ kódovým slovem 0, potom sekvence 01 může znamenat jak $\delta\alpha$, tak i β. Abychom odstranili tento problém, museli bychom mezi kódová slova vložit oddělovač, čímž ale zakódovanou zprávu prodloužíme a k požadované úspoře nedojde.

Již Claude E. Shannon tvrdil, že komprese má limit a tím je vždy entropie zdrojové zprávy. Čím je entropie nižší, tím vyšší je možnost komprese. Naopak čím je entropie vyšší, kvůli nepředvídatelnosti, schopnost komprese se snižuje. Pokud bychom chtěli komprimovat až za tento limit, museli bychom nutně část informace vypustit, což je ale přesně princip ztrátové komprese, kterou si nemůžeme vždy dovolit.

Kapitola 3

Statistické techniky komprese

Statistické kompresní metody využívají znalosti tzv. pravděpodobnostního modelu komprimovaných dat. Modelem může být například četnost výskytu jednotlivých symbolů v textu. Účinnost komprese je závislá na schopnosti co nejpřesněji modelovat zpracovávaná data. Čím více se model přibližuje realitě, tím je účinnost komprese vyšší. A naopak.

3.1 Pravděpodobnostní model

Pravděpodobnostní model přiřazuje pravděpodobnosti výskytu symbolům ve zdrojové zprávě. Na tomto základě například Huffmanovo kódování (viz 3.2 a 3.3) přiřazuje symbolům, které se v datech objevují častěji (mají vyšší pravděpodobnost výskytu), kratší kódová slova.

Podle toho, jakým způsobem model vzniká, ho můžeme označit jako statický, semiadaptivní, nebo adaptivní.

3.1.1 Statický model

Tento model je definován při implementaci kompresní metody a při použití se již nijak nemění. Výhodou je rychlost a jednoduchost vytvoření modelu. Například v případě, že budeme zpracovávat výstup pouze jednoho známého zdroje, se tímto způsobem vyhneme opakovanému vytváření modelu, které by vedlo ke stejným, nebo alespoň velmi podobným výsledkům. V opačném případě ale model nemusí datům vůbec odpovídat, čímž bude dosažená účinnost komprese velice nízká.

3.1.2 Semiadaptivní model

Komprimovaná data jsou jedním průchodem statisticky zpracována a následně je vytvořen odpovídající model. K samotné kompresi je ale nutný ještě druhý průchod daty s již vytvořeným modelem. Aby bylo možné data dekomprimovat, je nutné připojit model k datům. Model je sice přesný, ale velikost zkomprimované zprávy je větší o model. Navíc přístup s dvěma průchody daty činí tyto algoritmy neefektivními a v praxi se moc nepoužívají.

3.1.3 Adaptivní model

Tento model vzniká v průběhu zpracování dat a je postupně aktualizován. To platí i pro dekompresní algoritmus, ten vytváří model stejně jako kompresní algoritmus z části textu, kterou již dekomprimoval. Díky tomu není nutné model připojovat k datům a také procházet data dvakrát.

3.2 Semiadaptivní Huffmanovo kódování

Huffmanovo kódování je jednou z nejstarších kompresních technik, kterou publikoval již v roce 1952 David A. Huffman. Semiadaptivní dvouprůchodová verze byla od svého vzniku podrobena dalšímu výzkumu a postupně vylepšena až na adaptivní. Je založeno na dvou vlastnostech nejkratších prefixových[1] (jednoznačně dekódovatelných) kódů [7]:

1. Symbolům s vyšší pravděpodobností výskytu jsou přiřazována kratší kódová slova.
2. Dvěma symbolům s nejmenší pravděpodobností výskytu jsou přiřazována kódová slova stejné délky.

Algoritmus nejprve seřadí symboly sestupně podle pravděpodobnosti výskytu a poté z nich v krocích konstruuje strom od listů ke kořeni. V každém kroku jsou vybrány dva symboly s nejmenší pravděpodobností výskytu, z nich je vytvořen nový uzel, který je brán jako symbol s kumulovanou pravděpodobností odpovídající součtu dílčích pravděpodobností. Kroky opakujeme až do vybrání všech symbolů, kdy je kumulovaná pravděpodobnost výskytu rovna 1. Nakonec ohodnotíme hrany vystupující z uzlu vlevo číslem 0 a vpravo číslem 1. Kódová slova získáme čtením stromu od kořene k listům. [6], [7]

3.2.1 Postup kódování a dekódování zprávy

Při kódování zprávy zapisujeme na výstup kódová slova odpovídající čteným symbolům. Naopak při dekódování procházíme strom od uzlu k listům tak, jak jsou čteny jednotlivé znaky kódových slov. Pokud dojdeme do listu, přečetli jsme jeden původní symbol a můžeme jej vypsat.

3.2.2 Vzorový příklad

Postup lze nejlépe prezentovat na příkladu. Mějme za úkol zakódvat zprávu „MISSISSIPPI“ pomocí semiadaptivního Huffmanova kódování. Výsledný strom je zobrazen na obrázku 3.1 a je sestaven dle návodu popsaného v úvodu této podkapitoly. Místo pravděpodobností výskytu jsou použity absolutní četnosti symbolů v listech a kumulativní četnosti v dalších uzlech. Získaná kódová slova pro jednotlivé symboly jsou zobrazena v tabulce 3.1.

[1] Prefix značí několik shodných počátečních znaků různých řetězců.

Data po zakódování

Zakódovaná zpráva je tvaru `111|0|10|10|0|10|10|0|110|110|0`, kde je znak „|“ použit jako oddělovač jednotlivých kódových slov.

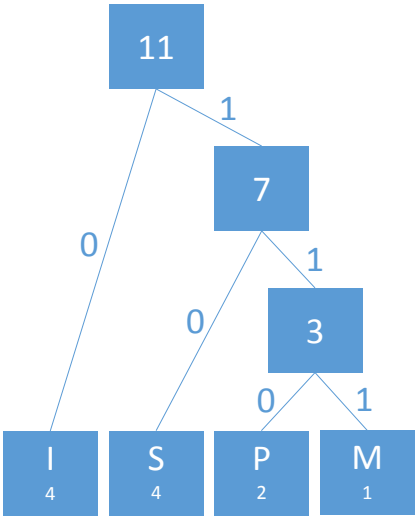

Obrázek 3.1: Strom vytvořený při semiadaptivním Huffmanově kódování

Zdrojový znak	Četnost výskytu	Kódové slovo
I	4	0
S	4	10
P	2	110
M	1	111

Tabulka 3.1: Kódová slova semiadaptivního Huffmanova kódu

3.3 Adaptivní Huffmanovo kódování

Adaptivní Huffmanovo kódování konstruuje strom při kompresi i dekompresi posloupností stejných kroků, tzv. mirroring. Strom je v každém kroku upraven tak, aby produkoval nejkratší kód pro do té doby zpracovanou část dat. Jak se strom mění, mění se i kódy přiřazené jednotlivým symbolům. Listy stromu obsahují symboly a jejich četnosti výskytu, vnitřní uzly obsahují kumulovanou četnost svých potomků.

Implementovaných verzí existuje několik. Níže je představena verze, kterou navrhl Jeffrey S. Vitter a ve které všechny uzly navíc obsahují pořadové číslo, které je využito při rozhodování při aktualizaci stromu. Nejvyšší pořadové číslo n určíme ze vztahu $n = 2m - 1$, kde m je počet znaků zdrojové abecedy. Také se zde využívají tzv. bloky – množiny uzlů se stejnou četností. Diagram aktualizace stromu po přečtení jednoho symbolu je možné vidět v příloze odkaz, způsob kódování a dekódování zprávy je popsán v části 3.3.1.

Algoritmus začíná pouze s uzlem označeným NYT (not yet transmitted), který symbolizuje všechny znaky, které se zatím ve stromu nevyskytují. Je-li ke zpracování načten symbol, který se ještě ve stromě nevyskytuje, je do výstupu vypsáno kódové slovo uzlu NYT následované nezakódovaným a dohodnutým tvarem zpracovávaného symbolu. Následně se

z uzlu NYT stane vnitřní uzel a jsou mu přiřazeni dva noví potomci: nový uzel NYT a list reprezentující právě zpracovávaný znak. Poté je strom aktualizován. Je-li ke zpracování načten ve stromě již obsažený symbol, je na výstup vypsáno pouze kódové slovo tohoto symbolu a strom je aktualizován.

Nezakódovaný tvar zpracovávaného symbolu může být například jeho osmibitový ASCII kód. Má-li zdrojová abeceda $\{a_1, a_2, \ldots, a_m\}$ počet znaků roven m, pak zvolíme e, r tak, aby splňovala $m = 2^e + r$ a $0 \leq r < 2^e$. Znak a_k poté kódujeme jako $(e+1)$-bitovou reprezentaci čísla $k-1$, je-li $1 \leq k \leq 2r$, jinak je a_k kódován jako e-bitová reprezentace čísla $k-r-1$. [6], [7]

3.3.1 Vzorový příklad

Pokusme se znovu zakódovat slovo MISSISSIPPI a uvažujme anglickou abecedu jako zdrojovou. Ta má 26 znaků, tedy $m = 26$, $e = 4$ a $r = 10$ a znaky číslujeme $a_1 = \text{A}$ atd.

Zakódování zprávy a vytvoření stromu

Začínáme se stromem, který obsahuje pouze kořen NYT. Čteme znak M a na výstup zapíšeme jeho pětibitový nezakódovaný tvar pro $k = 13$, tedy `01100`. Aktualizujeme strom. Čteme znak I, který se ve stromě také nevyskytuje. Na výstup zapíšeme kód uzlu NYT (nyní je to `0`) a pětibitový nezakódovaný tvar pro $k = 9$, tedy `01000`. Aktualizujeme strom. Dále čteme nový znak S. Na výstup zapíšeme kód uzlu NYT (nyní je to `00`) a pětibitový nezakódovaný tvar pro $k = 19$, tedy `10010`. Aktualizujeme strom. Dále čteme znak S, který ve stromu již je a tedy vypíšeme pouze jeho kód. Aktualizujeme strom. A tak pokračujeme pro všechny znaky slova. Výsledný strom je zobrazen na obrázku 3.2.

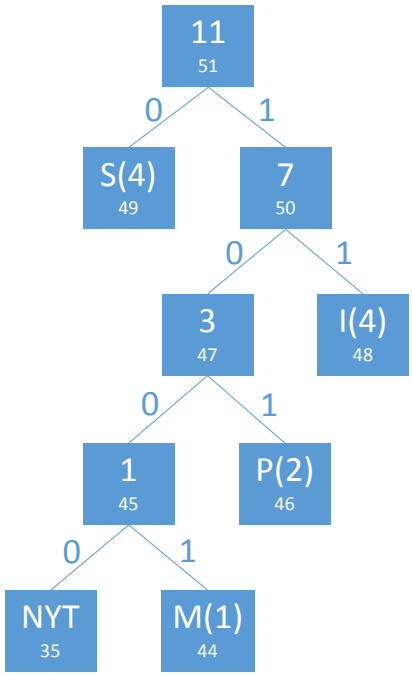

Obrázek 3.2: Strom vytvořený při adaptivním Huffmanově kódování

Zakódovaná zpráva

Výsledná zakódovaná zpráva je tvaru `01100|0|01000|00|10010|101|11|0|1|01|000|01111|1001|11`, kde jsem pro přehlednost vložil oddělovač „|“ oddělující jednotlivé významné bloky.

Dekódování zprávy

Přečteme $e = 4$ bitům znaků, jejichž hodnota jakožto čtyřbitového čísla je 6, což je menší než $r = 10$. Přečteme další znak, hodnota tohoto pětibitového čísla je 12 a tedy jsme přečetli symbol a_{13} = M. Aktualizujeme strom. Následuje 0, která je kódovým slovem pro uzel NYT, po něm vždy následuje nezakódovaný symbol. Obdobně jako pro M přečteme symbol a_8 = I. Aktualizujeme strom. Následuje kódové slovo uzlu NYT a symbol a_{19} = S. Dále čteme kódové slovo uzlu pro symbol S. Takto pokračujeme, dokud nepřečteme všechna slova zakódované zprávy.

Kapitola 4

Slovníkové techniky komprese

V předchozí kapitole jsme si představili kompresní techniky, které předpokládají zdroje generující posloupnosti nezávislých symbolů a snaží se vytvořit statistický model dat. Účinnost komprese pak závisí na přesnosti modelu. Slovníkové techniky, které popíšu v této kapitole, nepoužívají statistický model ani kódy s různou délkou kódových slov. Místo toho vyhledávají opakující se části textu, tzv. fráze, ty udržují ve slovníku a na výstup vypisují pouze odkaz na příslušné místo ve slovníku. Slovníkem zde může být jak část již zpracovaných dat, tak i vlastní struktura v paměti. Podobně jako u statistických modelů existují statické a adaptivní slovníky.

4.1 Základy slovníkové komprese

Základní princip a problematiku slovníkové komprese si můžeme představit na jednoduchém příkladu. Mějme text složený ze slov délky 5, kde jsou slova libovolně složena z arabských číslic a písmen A–F. Takováto abeceda má tedy 16 znaků. Pokud budeme předpokládat, že mají všechny znaky stejnou pravděpodobnost výskytu, budeme pro vytvoření binárního kódu potřebovat 4 bity na znak a 20 bitů k zakódování každého slova (těchto slov je 2^{20}). Nyní vytvoříme statický slovník, který bude obsahovat 256 nejčastěji se vyskytujících slov.

Při kompresi budeme na výstup zapisovat jeden bit, charakterizující, zda je či není zpracovávané slovo obsaženo ve slovníku (např. 1 a 0), následovaný osmibitovým indexem slova (pokud je ve slovníku) nebo dvacetibitovým kódem slova (pokud ve slovníku není). To znamená, že pro slova ve slovníku potřebujeme pouze 9 bitů, zatímco pro slova, která ve slovníku nejsou, potřebujeme bitů 21.

Pro to, aby byl takovýto způsob komprese účinný, je rozhodující pravděpodobnost, že je zpracovávané slovo ve slovníku. To lze vyjádřit pomocí vzorce $R = Sp + T(1 - p)$, kde R je průměrný počet bitů na slovo, S počet bitů pro slovo ve slovníku, T počet bitů pro slovo mimo slovník a p je pravděpodobnost, že je zpracovávané slovo ve slovníku. V našem případě musí být $R < 20$, což je splněno pro $p \geq 0,08\overline{3}$.

Pro pravděpodobnost p blízkou číslu $0,08\overline{3}$ je účinnost komprese nízká a tedy nezajímavá. Pro vysokou účinnost potřebujeme pravděpodobnost p co možná největší. Toho lze dosáhnout zvětšením slovníku, což s sebou nese vyšší paměťové nároky a časově náročnější prohledávání, nebo pečlivým výběrem slov ve slovníku.

4.1.1 Typy slovníků

V praxi jsou známy dva typy slovníků: statický a adaptivní. Podobně jako v případě statistických technik komprese (viz 3.1) je volba kompresního algoritmu se statickým slovníkem nejvhodnější, pokud známe dobře zdroj a komprimujeme zprávy výhradně tohoto zdroje. Proti tomu adaptivní slovník lze použít na neznámá data.

Většina kompresních algoritmů s adaptivním slovníkem je založena na pracích pánů Abrahama Lempela a Jacoba Ziva, kteří v letech 1977 a 1978 představili dva různé přístupy k vytváření slovníku. Podle nich jsou vzniklé algoritmy označovány jako algoritmy rodiny LZ77, resp. LZ78.

4.2 LZ77

Princip tohoto algoritmu je založen na okně klouzajícím po zpracovávaných datech. Toto okno se dělí na dvě podokna (viz obrázek 4.1). V prvním je část ještě nezpracovaných dat. Ve druhém je pak část již zkomprimovaných dat, ve které jsou vyhledávány fráze a tedy funguje jako slovník. Velikost tohoto podokna je pevně daná jakožto kompromis mezi co největší velikostí, která zvyšuje pravděpodobnost nalezení fráze, a co nejmenší velikostí, která snižuje dobu vyhledávání fráze.

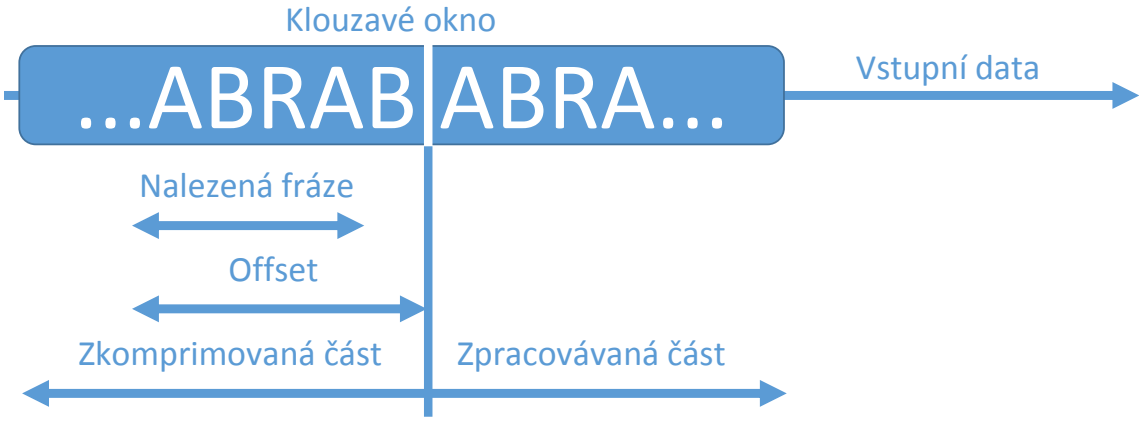

Obrázek 4.1: Schéma algoritmu LZ77, jenž využívá klouzavé okno

Tento algoritmus má velmi dobrý kompresní poměr pro data, ve kterých se shodné fráze vyskytují blízko sebe. To je dáno tím, že obsahem slovníku jsou poslední zpracovaná data, která se mění s posunem okna.

4.2.1 Princip komprese

V každém kroku kompresního algoritmu se v podokně zkomprimované části hledá nejdelší fráze. Znaky jsou procházeny zprava doleva až do shody prvního znaku fráze, kdy je zaznamenána délka fráze a vzdálenost fráze od pravého kraje podokna (offset), poté se pokračuje ve vyhledávání delší fráze dále vlevo. Nejdelší nalezená fráze je zakódována pomocí trojice (offset, délka fráze, následující znak (ve zpracovávaných datech)) a okno se posune o (délka fráze + 1) vpravo. Není-li nalezena shoda, je zakódován první znak ve zpracovávané části jako (0, 0, první znak). Tím je zaručeno, že se okno posune v každém kroku alespoň o jeden znak.

4.2.2 Příklad komprese

Zkusme zakódovat část textu začínajícího znaky ABRAKADABRAK s délkou podokna slovníku 7 znaků. V prvním kroku zakódujeme znak A, protože část slovníku je zatím prázdná, a posuneme okno o jeden znak doprava. Podobně zakódujeme i následující dva znaky B a R. Kódování jednotlivých znaků s offesetem 0 a délkou 0 je typickým projevem na začátku kompresního algoritmu, kdy je slovník ještě prázdný. V kroku 4 nalezneme frázi A délky 1 s offsetem 3 a posuneme okno o 2 znaky doprava. V dalším kroku úplně stejně zakódujeme další frázi A. V posledním kroku pak nalezneme frázi ABRA délky 4 s offsetem 7, kterou zakódujeme jako (7,4,K). Celý postup je zobrazen v tabulce 4.1.

Krok	Text	Fráze	Kódování
1	| ABRAK | ADABRAK...		(0,0,A)
2	A | BRAKA | DABRAK...		(0,0,B)
3	AB | RAKAD | ABRAK...		(0,0,R)
4	ABR | AKADA | BRAK...	A	(3,1,K)
5	ABRAK | ADABR | AK...	A	(2,1,D)
6	ABRAKAD | ABRAK | ...	ABRA	(7,4,K)

Tabulka 4.1: Kódování textu pomocí algoritmu LZ77

4.2.3 Princip dekomprese

Postup dekomprese je mnohem jednodušší a rychlejší než kompresní algoritmus. V paměti si udržuje pouze data slovníku, ve kterém jednoduše vyhledává fráze dle postupně dekódovaných trojic. Offset a délka fráze určují frázi jednoznačně a není tedy nutné prohledávat celý slovník. LZ77 je tedy asymetrický kompresní algoritmus.

4.2.4 Variace algoritmu LZ77

Vylepšených verzí algoritmu LZ77 vzniklo několik a lze je rozdělit do skupin dle způsobu zlepšení. První skupina je zaměřena na efektivní kódování výstupu, tj. výše popsaných trojic, pomocí kódu s proměnlivou délkou slov. Reprezentantem takového kódování jsou semiadaptivní a adaptivní Huffmanovo kódování (viz 3.2 a 3.3). Další skupina pracuje s proměnlivou velikostí klouzavého okna, což pro případ jeho zvětšení nese požadavek na implementaci efektivnějších vyhledávacích algoritmů.

Velmi známá verze je algoritmus LZSS, který odstraňuje neefektivní chování původního algoritmu, kdy je v jednom kroku kódován i následující znak, kterým může začínat fráze existující ve slovníku. Místo toho jsou nalezené fráze kódovány pomocí trojice (příznak, offset, délka fráze) a samotné znaky, které nejsou nalezeny ve slovníku, pomocí dvojice (příznak, znak).

4.3 LZ78

Algoritmus je založen na vyhledávání opakujících se frází ve vlastní paměťové struktuře. Tento slovník je na začátku procesu prázdný a postupně jsou do něho při zpracování na indexované pozice vkládány jednotlivé fráze. Jednoduché schéma je zobrazeno na obrázku 4.2. Podobně jako v případě LZ77 je velikost slovníku dána kompromisem mezi počtem uložených frází a rychlostí vyhledávání.

V případě, že je slovník zcela naplněn, algoritmus LZ78 neříká přesně, co v takové situaci udělat. Existuje ale několik možností, které se v praxi používají a jsou vhodné pro různé případy.

- Dále využívat slovník jako statický. To je vhodné v případě, že se stejné fráze opakují v celé šířce dat.
- Slovník úplně vymazat a začít ho plnit znovu. Takový přístup lze s výhodou aplikovat na data, ve kterých lze nalézt velké ucelené bloky, ve kterých se opakují různé fráze. Zároveň tento přístup připomíná princip algoritmu LZ77, kdy je jako slovník použita část blízkých předcházejících dat.
- Ze slovníku mazat fráze s nízkým výskytem. Takto adaptivní slovník by byl vhodný univerzálně, nicméně není znám algoritmus, který by dokázal určit, kolik a kterých frází má být smazáno.

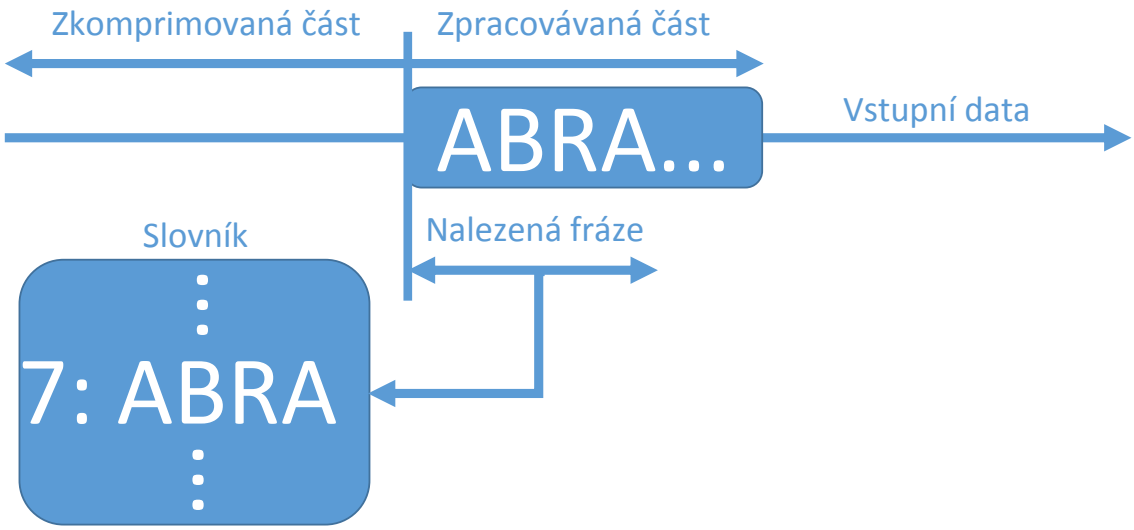

Obrázek 4.2: Schéma algoritmu LZ78, jenž využívá vlastní slovník

Vhodnou paměťovou strukturou pro uchovávání slovníku je strom, jehož uzly mohly mít tolik potomků, kolik je znaků zdrojové abecedy. V kořeni je prázdné slovo a při vyhledávání fráze se každým načteným znakem posuneme do potomka v příslušné větvi (pokud existuje).

4.3.1 Princip komprese

Na počátku je ve slovníku na pozici 0 pouze prázdné slovo[1] ε. Při zpracování dat jsou na další pozice 1, 2 atd. vkládány nové fráze. Je-li na vstupu přečten znak s, algoritmus se ve slovníku pokusí nalézt jednoznakovou frázi s. Pokud není tato fráze nalezena, je vložena na volnou pozici s nejnižším indexem a na výstup je zapsána dvojice $(0, s)$, kde 0 je index prázdného slova. Tato dvojice znamená zakódování řetězce εs (zřetězení prázdného slova a znaku s). Naopak je-li fráze s ve slovníku nalezena, je ze vstupu přečten další znak t a ve slovníku je hledána dvouznaková fráze st. Pokud je fráze nalezena, pokračuje načítání dalších znaků a hledání ve slovníku. Pokud fráze nalezena není, je na výstup zapsána dvojice (i, t), kde i je index prefixové fráze s. Tento proces pokračuje, dokud nejsou zpracována všechna data na vstupu.

4.3.2 Příklad komprese

Zkusme pro příklad zakódovat část textu začínající slovem ABRAKADABRAK. Stav slovníku a výstup po kompresi můžeme vidět v tabulce 4.2. V prvních třech krocích (indexy 1, 2 a 3) jsou komprimovány pouze jednoznakové fráze, v dalších krocích již existují fráze A, resp. AB a tedy jich můžeme využít k zakódování delších frází.

Slovník		Výstup
Index	Fráze	
0	ε	
1	A	$(0, \mathrm{A})$
2	B	$(0, \mathrm{B})$
3	R	$(0, \mathrm{R})$
4	AB	$(1, \mathrm{B})$
5	ABR	$(4, \mathrm{R})$
6	AK	$(1, \mathrm{K})$

Tabulka 4.2: Kódování textu pomocí algoritmu LZ78

4.3.3 Princip dekomprese

Při rekonstrukci dat jsou čteny jednotlivé dvojice (index, znak) a slovník je vytvářen pomocí úplně stejných kroků jako v případě komprese. Je tedy složitější než dekompresní algoritmus LZ77. Plátí, že je-li nějaká fráze ve slovníku, pak jsou v něm i všechny její prefixy. Ty jsou nutné pro hledání delších frází, neboť kompresní algoritmus se odkazuje na prefixové fráze o jeden znak kratší.

4.3.4 Variace algoritmu LZ78

Podobně jako v případě algoritmu LZ77 vniklo i množství variant postavených na myšlence algoritmu LZ78 upravujících ty části, které považují autoři za neefektivní. Mezi nejvýznamnější se řadí metoda LZW vycházející z předpokladu, že kódovat jednotlivé znaky pomocí výše zmíněných dvojic je neefektivní. Místo toho na počátku kompresního procesu inicializuje slovník všemi jednoznakovými frázemi znaků zdrojové abecedy. Je-li hledaná fráze

[1] Prázdná posloupnost znaků, slovo délky 0.

nalezena, pokračuje načtením dalšího znaku a hledáním delší fráze. Naopak, není-li fráze nalezena, je vložena do slovníku, ale na výstup kóduje pouze index o jeden znak kratší fráze nalezené ve slovníku (nalezení jednoznakové fráze je zaručeno díky původní inicializaci slovníku). Další hledaná fráze začíná posledním zpracovaným znakem, tj. posledním znakem fráze uložené do slovníku v předchozím kroku.

Kapitola 5

Existující algoritmy pro kompresi XML

Velikost XML dokumentu danou vlastností formátu, kdy se schéma opakuje pro každý záznam, lze při kompresi redukovat pomocí například gzip[1]. Jiným přístupem může být navržení kompresního algoritmu speciálně pro XML. Algoritmy využívající znalost vnitřní struktury XML se anglicky nazývají XML aware. Díky této znalosti dokážou data předpřipravit tak, aby byla komprese co nejefektivnější. Pro kompresi samotnou jsou používány algoritmy již zmiňované v kapitolách 3 a 4 a jejich upravené varianty.

XML aware algoritmy můžeme rozdělit dle několika kritérií a to zda podporují dotazování a přístup do komprimovaných dat nebo zda je či není dekompresní algoritmus závislý na přístupu k XML schématu. Z druhé skupiny je častější použití algoritmů, které jsou na schématu nezávislé, protože pro dekompresi není vždy možné přístup ke schématu zaručit.

5.1 XMill

Algoritmus XMill, který nepodporuje dotazování do zkomprimovaných dat, představili pánové Hartmut Liefke a Dan Suciu v roce 2000. Jeho architektura využívá knihovnu kompresních algoritmů zlib, specifické kompresory pro určitý typ dat a navíc podporuje použití kompresorů vytvořených uživatelem pro speciální typy dat. Rozhodnutí, který kompresní algoritmus bude použit, je provedeno na základě znalosti tagů. Architektura algoritmu XMill je postavena na třech základních principech [4]:

- Struktura XML složená z tagů a atributů tvoří strom. Data, obsah elementů a hodnoty atributů jsou reprezentovány jako řetězce. Stromová struktura a data jsou komprimovány odděleně.
- Datové položky stejných elementů jsou seskupeny do jednoho kontejneru a každý kontejner je komprimován odděleně.
- Dle typu dat (text, číslo apod.) je pro kompresi kontejneru použit vhodný kompresní algoritmus, tzv. sémantický kompresor.

[1] GNU zip, software pro kompresi dat využívající LZ77 a Huffmanovo kódování.

5.1.1 Popis architektury

Architektura algoritmu XMill je zobrazena na obrázku 5.1. XML dokument je nejprve zpracován pomocí SAX[2] parseru, který každý prvek pošle do Path procesoru. Path procesor rozhodne, do kterého existujícího kontejneru prvek vloží nebo zda má vytvořit kontejner nový. Ke každému kontejneru může být uživatelem přiřazen sémantický kompresor a to buď atomický implementovaný v XMill, kombinace atomických pro komplexnější typy, nebo vlastní. Kontejnery jsou plněny až do předem určené velikosti (defaultně je to 8 MB), je-li tato velikost dosažena, je kontejner zkomprimován pomocí gzip, uložen na disk a komprese dále pokračuje. Díky tomu jsou data rozdělena do vzájemně nezávislých bloků.

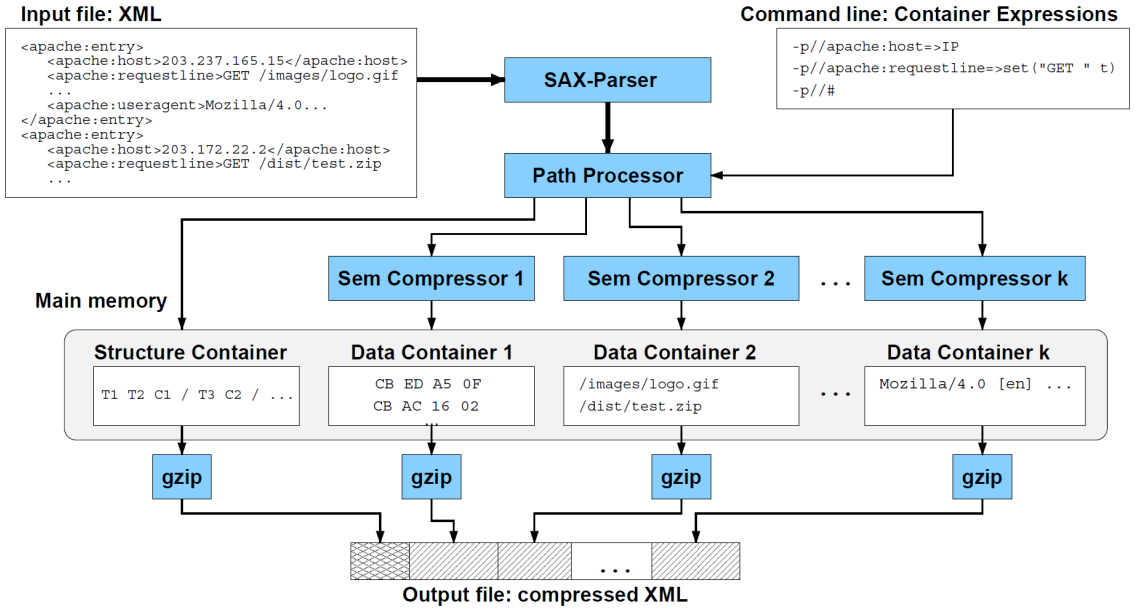

Obrázek 5.1: Architektura algoritmu XMill [4]

5.1.2 Oddělení struktury od dat

Struktura XML je složena z tagů a atributů. Počáteční tagy a atributy jsou kódovány slovníkovou metodou a nahrazeny indexem ve slovníku, kladným celým číslem. Ukončující tag je kódován hodnotou 0, při dekompresi je díky syntaxi zřejmé, který tag je ukončován. Datové hodnoty jsou nahrazeny záporným indexem kontejneru, do kterého byly přiřazeny. [4]

Pro příklad zpracujeme následující informace o článku:

```
<article mdate="2011-01-11" key="journals/acta/GoodmanS83">
  <author>
    <name>Nathan Goodman</name>
    <title>Mr.</title>
  </author>
  <title>NP-complete Problems Simplified on Tree Schemas.</title>
</article>
```

[2]Simple API for XML.

Tagy zde jsou `article`, `author` a `title` a atributy `mdate` a `key`. Po zpracování dostaneme výstup `1 2 -3 3 -4 0 4 5 -5 0 6 -6 0 0 7 -7 0 0`. Lze si povšimnout, že indexování kontejnerů začíná až číslem 3, to proto, že index 0 je rezervován pro kontejner struktury, 1 pro kontejner bílých znaků (umožňuje zachování formátovacích mezer) a 2 pro kontejner obsahující procesní instrukce, DTD a jiné.

5.1.3 Seskupení dat stejného významu

Mapování mezi daty a kontejnery provádí Path procesor na základě cesty k datům (path) a na uživatelem definovaném regulárním výrazu container expression. Základní myšlenkou je hodnotám pro každý tag nebo atribut přiřadit vlastní kontejner. Cesta k datům v příkladě z předchozí části 5.1.2 vypadá například pro atribut takto `/article/@key` a pro tag takto `/article/author/name`. Pomocí container expression je možné nastavit pravidla, kdy budou například hodnoty různých tagů ukládány do stejného kontejneru. [4]

5.1.4 Sémantická komprese

Jak již bylo zmíněno v úvodu popisu tohoto algoritmu, jsou podporovány 3 druhy sémantických kompresorů: atomické, kombinované a definované uživatelem. Atomických kompresorů je 8, například textový kompresor `t`, který řetězec pouze zkopíruje na výstup (ten bude později zkomprimován pomocí gzip), nebo kompresor `u`, který komprimuje kladná celá čísla.

Kombinovaný kompresor je vhodný pro hodnoty, ve kterých lze nalézt nějaký vzor nebo strukturu. Jako příklad lze uvést sekvenční kompresor pro kompresi IP adresy `seq(u8 "."u8 "."u8 "."u8)`, což znamená sekvenci čtyř kladných celých čísel menších než 256 oddělených tečkou.

Vlastní kompresory lze s výhodou použít na data, která mají strukturu složitou nebo velmi těžce vyjádřitelnou pomocí kombinovaných kompresorů. Autoři jako příklad takových dat uvádějí DNA sekvence. Aby bylo možné data komprimovaná za pomoci vlastních kompresorů zpětně rekonstruovat, musí mít dekompresní algoritmus samozřejmě také přístup k použitému vlastnímu kompresoru. [4]

5.1.5 Nedostatky tohoto přístupu

Způsob rozdělení struktury a dat různých typů zvlášť do jednotlivých bloků v algoritmu XMill brání úpravě komprimovaných dat nebo efektivnímu dotazování nad nimi. Možnost dotazů nad daty je ale pro některé aplikace velmi důležitá a v případě algoritmů typu LZ nebo XMill by to znamenalo zbytečně náročnou operaci: dekomprimovat data, provést dotazy nebo úpravy a data zpět zkomprimovat.

5.2 XGrind

Na základě výše zmíněných požadavků publikovali pánové Pankaj M. Tolani a Jayant R. Haritsa v roce 2002 článek, ve kterém představili nový kompresní nástroj, který přímo podporuje dotazování nad zkomprimovanými daty. Ten, namísto rozdělení struktury celého

dokumentu, komprimuje obsah jednotlivých elementů a atributů pomocí semiadaptivního Huffmanova kódování (viz 3.2), které je nezávislé na kontextu.

Díky tomu podporuje dotazy typu úplná shoda nebo shoda prefixu tak, že je dotaz zakódován pomocí stromu vytvořeného při kompresi, následně jsou ve zkomprimovaném souboru vyhledána data odpovídající dotazu a pouze ta jsou dekomprimována a zobrazena uživateli. To odpovídá nejmenšímu možnému objemu dat, který je nutný dekomprimovat. Algoritmus navíc podporuje i intervalové dotazy a dotazy na podřetězec, ty ale vyžadují částečnou dekompresi příslušných elementů či atributů. [10]

5.2.1 Kompresní techniky

Způsob kódování tagů a atributů je velice podobný jako v případě algoritmu XMill (viz 5.1.2). Každý počáteční tag je kódován jako zřetězení `T` a unikátního indexu tagu. Podobně jsou atributy kódovány zřetězením `A` a unikátního indexu atributu. Koncové tagy jsou kódovány symbolem `/`, což je možné díky syntaxi. Výčtové typy, jejichž definice je uvedena v DTD nebo ve schématu dokumentu, jsou kódovány pomocí schématu $\log_2 n$, kde n je počet prvků výčtového typu.

Aby bylo možné se efektivně dotazovat do komprimovaných dat, je pro kompresi hodnot elementů a atributů použito kompresní schéma, které řetězci přiřadí kód nezávislý na místě výskytu v dokumentu. To splňuje použité semiadaptivní Huffmanovo kódování (viz 3.2), které ve dvou průchodech nejprve vytvoří kódy na základě statistiky a poté data zakóduje. V algoritmu XGrind nejsou kódovány jednotlivé znaky, ale celé hodnoty, které spolu sémanticky souvisejí. [10]

Zakódujme nyní zkrácenou verzi příkladu k algoritmu XMill:

```
<article mdate="2011-01-11">
    <author>
        <name>Nathan Goodman</name>
    </author>
    <title>NP-complete Problems</title>
</article>
```

Výstupem bude sekvence `T0 A0` *huff*(`2011-01-11`) `T1 T2` *huff*(`Nathan Goodman`) `/ / T3` *huff*(`NP-complete Problems`) `/ /`, kde je výrazem *huff*(`A`) myšlen semiadaptivní Huffmanův kód řetězce `A`.

5.2.2 Popis architektury

Schéma architektury lze vidět na obrázku 5.2, jehož originální verze byla publikována v [10]. Hlavní prvkem je XGrind Kernel, který nejprve vyzve DTD-Parser k načtení DTD a inicializaci Frequency Tables naplněním všemi unikátními tagy a nevýčtovými atributy a Symbol Table naplněním výčtovými atributy. Následně XGrind Kernel vyzve XML-Parser k přečtení zpracovávaného dokumentu a naplnění Frequency Tables statistikou počtu výskytů jednotlivých prvků. Nakonec XGrind Kernel znovu vyzve XML-Parser, aby vytvořil zakódovanou (viz 5.2.1) podobu XML dokumentu. [10]

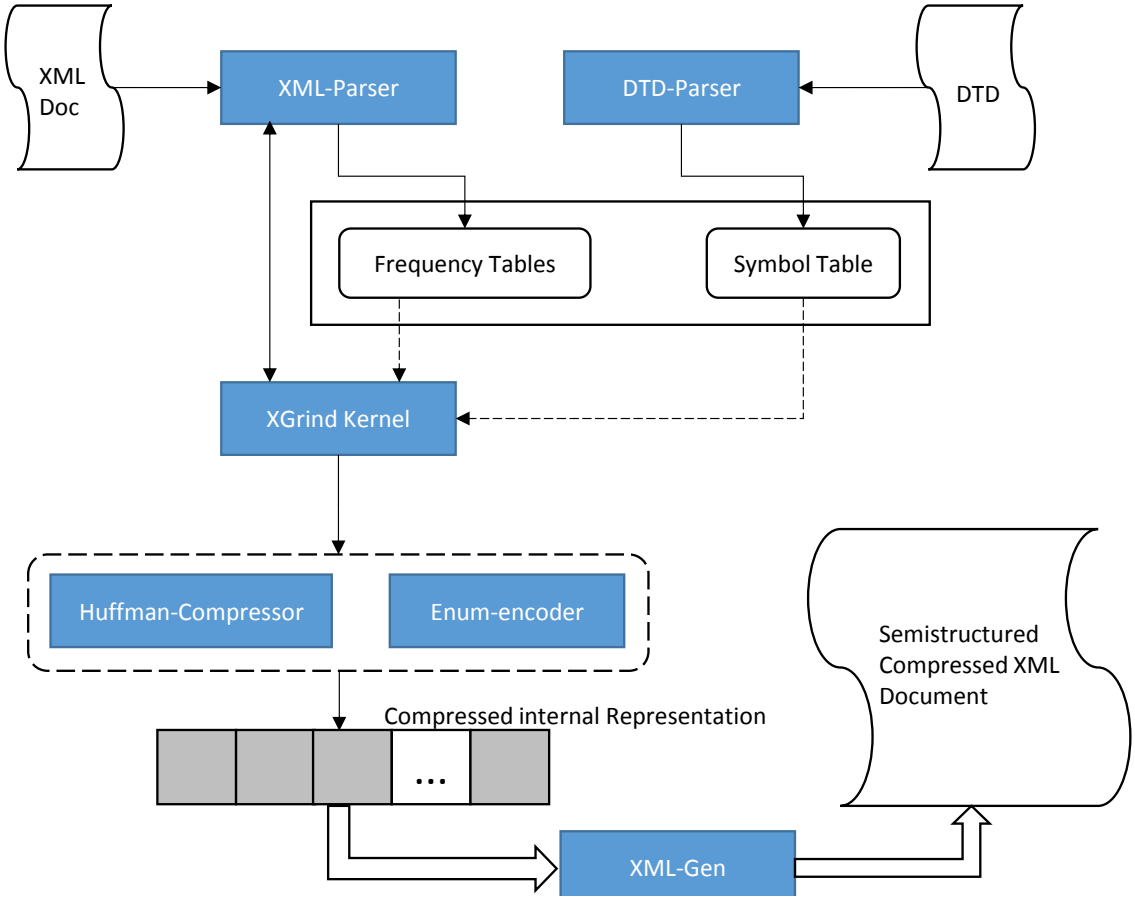

Obrázek 5.2: Architektura algoritmu XGrind

5.2.3 Dotazování

Zpracování dotazů je implementováno pomocí slovníkového analyzéru, který poskytuje kódy tagů, atributů a hodnot, a parserem, který se stará o vzájemné porovnávání dotazu s daty. Parser prochází XML dokument do hloubky jako strom a uchovává si informaci o místě (cesta), kde v dokumentu se právě nachází, a obsah uzlů, které právě zpracovává.

Pro dotazy na přesnou a prefixovou shodu jsou zakódovány cesta a dotaz a při hledání jsou data označena jako vyhovující dotazu pouze v případě, že požadovaná cesta odpovídá aktuální pozici parseru v zakódovaných datech a zakódovaná verze dotazu odpovídá obsahu uzlu. Pro dotazy na rozsah nebo částečnou shodu musí být data ve vybraných uzlech dekomprimována a porovnání je provedeno na jejich původních verzích. [10]

Kapitola 6

Existující algoritmy pro kompresi JSON

JSON byl navržen jako odlehčená varianta způsobu formátování dat proti XML, čímž byla odstraněna i redundance při použití počátečního a ukončovacího tagu. Po seznámení s jeho definicí a syntaxí je zřejmé, že zde již nezbývá moc prostoru k dalšímu odlehčení. Podíváme-li se ale na data zapsaná v tomto formátu, která mohou obsahovat například výstup SQL příkazu SELECT nad databází, můžeme vidět, že se zde některé prvky přece jen opakují. Jsou to klíče, včetně uvozovek, v jednotlivých objektech, které stačí zapsat pouze jednou. Tohoto poznatku využívají i dva vybrané algoritmy JSONH a CJSON, které jsou specifické tím, že výstupem z nich je validní JSON. Rád bych čtenáře upozornil, že algoritmů pro kompresi JSON neexistuje mnoho, resp. jsou si velice podobné myšlenkou, provedením i názvy.

S daty v tomto formátu nepracujeme jako s obyčejným textem, ale převedeme do paměti jako hodnoty (pole, objekty atd.), což odpovídá zpracování pomocí JavaScriptu. Tomu odpovídá i terminologie použitá v této kapitole, která byla popsána v části 1.2.2.

6.1 JSONH

Tento algoritmus dovoluje komprimovat pouze homogenní kolekce dat, v terminologii JSON jde o pole objektů, které mají stejný počet klíčů se stejnými názvy. Homogenitu dat musí zaručit uživatel, algoritmus samotný toto nikterak neošetřuje. Autor projektu JSONH [1], kde je algoritmus implementován, na serveru github.com uvádí, že data mohou být v některých případech zmenšena až na 30 %.

6.1.1 Vzorová data

Mějme homogenní kolekci zaměstnanců firmy, ve které máme uložené databázové id, příjmení a pozici, na které zaměstnanec pracuje. Část této kolekce vypadá následujícím způsobem:

```
[ { "id" : 1, "name" : "Sánchez", "position" : "Manager" },
    { "id" : 2, "name" : "Duffy", "position" : "Programmer" },
    { "id" : 3, "name" : "Tamburello", "position" : "Programmer" } ]
```

6.1.2 Postup komprese

1. Textová data jsou převedena na pole objektů.
2. Z prvního objektu v poli jsou určeny klíče a jejich počet.
3. Ze všech objektů v poli jsou postupně vyzvednuty hodnoty pro příslušné klíče, přičemž je zachováno pořadí klíčů, jak jsme jej získali v kroku 2.
4. Je vytvořeno pole, které obsahuje prvky: počet klíčů, seznam klíčů a hodnoty vyzvednuté v kroku 3.
5. Vytvořené pole serializujeme jako JSON do řetězce nebo souboru.

Data po kompresi mají následující podobu:

```
[ 3, "id", "name", "position", 1, "Sánchez", "Manager", 2, "Duffy",
    "Programmer", 3, "Tamburello", "Worker" ]
```

6.1.3 Postup rekonstrukce dat

1. Textová data jsou převedena na pole hodnot.
2. Z prvního prvku v poli určíme počet klíčů, označíme n.
3. Z prvků 2 až $n + 1$ určíme klíče.
4. Z následujících prvků (po $n + 1$) rekonstruujeme původní objekty až do konce pole a ukládáme je do pole nového.
5. Nové pole serializujeme jako JSON do řetězce nebo souboru.

6.2 CJSON

Proti JSONH dokáže algoritmus CJSON komprimovat i nehomogenní data. K tomu, aby bylo při kompresi dosaženo významné úspory, je nutná určitá struktura dat. Tu bych přirovnal k dědičnosti, jak ji známe z principů objektově orientovaného programování. To znamená, že data lze popsat pomocí tříd, které sdílejí některé členy. Účinnost komprese závisí na poměru počtu tříd a množství dat k nim příslušných. Platí, že čím menší počet tříd a větší množství příslušných dat, tím větší je kompresní účinnost. Za ideál lze potom považovat homogenní data, tedy případ kdy stačí k popisu pouze jedna třída, ke které přísluší všechna data.

Algoritmus v průběhu komprese vytváří postupně strom šablon, který je na závěr vložen do výstupu ve formě jednotlivých šablon, která využívá již zmiňované dědičnosti. Konstrukce stromu je zobrazena na obrázku 6.1.

6.2.1 Vzorová data

Mějme kolekci rovinných geometrických útvarů, která obsahuje bod, kružnici a obdélník v tomto pořadí. Tato kolekce může vypadat následujícím způsobem:

```
[ { "souřadniceX" : 5, "souřadniceY" : 10 },
    { "souřadniceX" : 8, "souřadniceY" : 4, "poloměr" : 3 },
    { "souřadniceX" : 7, "souřadniceY" : 1, "výška" : 4, "šířka" : 2 } ]
```

6.2.2 Postup komprese

1. Textová data jsou převedena na pole objektů.
2. Ze všech objektů v poli jsou postupně vyzvednuty hodnoty a uloženy do nového pole objektů. Tyto objekty obsahují pouze pole příslušných hodnot. Zároveň je konstruován strom šablon.
3. Ze stromu šablon je vytvořeno pole šablon. Šablona je pole obsahující identifikátor šablony, ze které dědí, a klíče. Identifikátor 0 je rezervován pro šablonu odpovídající prázdnému objektu.
4. Objekty s hodnotami jsou doplněny o identifikátor odpovídající šablony.
5. Ze vzniklých polí vytvoříme objekt obsahující identifikátor kompresního algoritmu (klíč `"f"`), pole šablon (klíč `"t"`) a pole hodnot (klíč `"v"`) (viz 6.2.2).
6. Objekt vzniklý v bodu 5 serializujeme jako JSON do řetězce nebo souboru.

Během komprese byl sestrojen strom podobně, jako je tomu na obrázku 6.1. Popsané uzly (např. bod, kružnice atd.) odpovídají jednotlivým šablonám z nichž šablona pro prázdný objekt je defaultní, se kterou algoritmus začíná a ze které výsledný strom staví.

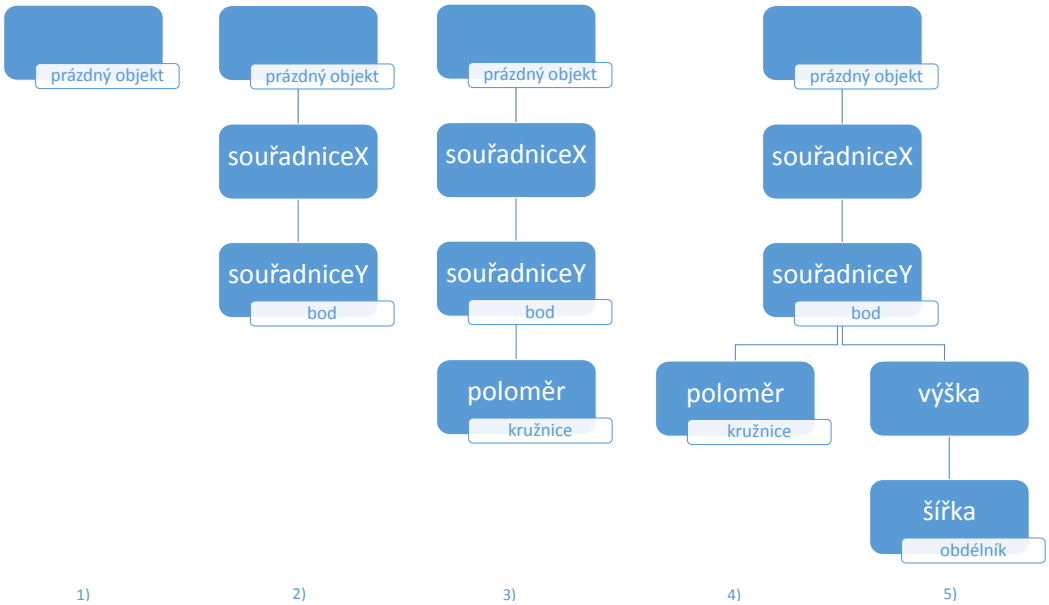

Obrázek 6.1: Postup vytvoření stromu šablon

Data mají po kompresi následující tvar:

```
{   "f" : "cjson",
    "t" : [ [0, "souřadniceX", "souřadniceY"], [1, "poloměr"],
            [1, "výška", "šířka"] ],
    "v" : [ { "" : [1, 5, 10] }, { "" : [2, 8, 4, 3] },
            { "" : [3, 7, 1, 4, 2] } ] }
```

6.2.3 Postup rekonstrukce dat

1. Textová data jsou převedena na pole hodnot.
2. Vytvoříme pole, do kterého postupně vkládáme objekty vzniklé z prvků pole hodnot a příslušných šablon.
3. Tuto kolekci serializujeme jako JSON do řetězce nebo souboru.

Kapitola 7

Vlastní implementace vybraných kompresních algoritmů

7.1 Technická specifikace

7.1.1 Vývojové prostředí a programovací jazyk

Na základě osobních preferencí jsem zvolil programovací jazyk C# verze 5.0, který poskytuje sofistikované a otestované nástroje pro práci s XML i JSON, a vývojové prostředí Microsoft Visual Studio Ultimate 2013, které poskytuje plnou podporu pro práci se zvoleným jazykem.

Dalšími použitými nástroji jsou framework NUnit verze 2.6 pro účely testování, ReSharper 8.0.1 pro správu testů a refaktorování[1] a verzovací systém Git, jehož podpora je ve Visual Studiu přímo implementována.

7.1.2 Implementace a testování

Při implementaci jednotlivých algoritmů jsem postupoval metodou vývoje řízeného testy (aglicky Test Driven Development). Při té programátor nejprve napíše neprocházející test, který definuje výchozí a požadovaný stav, a až poté implementuje logiku tak, aby test prošel. Díky vhodně napsané sadě testů je možné velice rychle a snadno odhalit chybu při další implementaci nebo refaktorování.

7.1.3 Projekt

Výstupem mé práce je knihovna tří vybraných kompresních algoritmů, které komprimují jeden zadaný soubor. Struktura knihovny je zobrazena na obrázku 7.1. Každému algoritmu odpovídá jedna příznačně pojmenovaná třída, jejíž veřejné rozhraní poskytuje metody `Compress` a `Decompress`. Tyto metody na vstupu očekávají cestu k souboru, který má být zpracován, a po úspěšném zpracování všech dat na stejném umístění vytvoří soubor s komprimovanými/dekomprimovanými daty.

[1] Refaktorování je proces úprav kódu vedoucí ke zlepšení jeho struktury, ale nemající vliv na funkčnost.

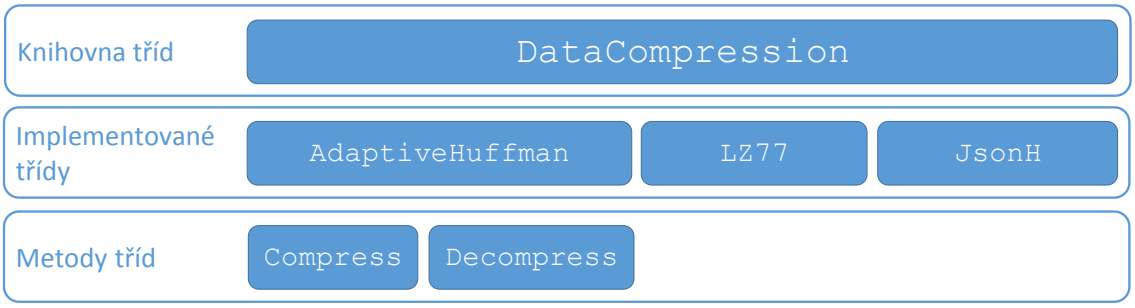

Obrázek 7.1: Struktura knihovny kompresních algoritmů

7.2 Vybrané algoritmy

7.2.1 Adaptivní Huffmanovo kódování

Ze statistických kompresních metod jsem zvolil Vitterovu verzi adaptivního Huffmanova kódování, která je považována za složitější na implementaci, ale proti jiným verzím staví vyváženější stromy a tedy generuje kratší kódová slova. Uživatel má k dispozici třídu `AdaptiveHuffman` s veřejnými metodami `Compress` a `Decompress`.

Jádrem algoritmu je ale třída `VitterTree`, která implementuje logiku chování stromu. Pro každý přečtený znak je při kompresi zavolána jeho metoda `AddChar` (viz algoritmus 1), která provede aktualizaci stromu dle algoritmu 2 a vrátí binární kód znaku ve stromu.

Algoritmus 1: `AddChar`

Vstupní parametry: ASCII kód znaku `Z`
Výstupní parametry: binární kód vloženého znaku

```
 1 if strom obsahuje uzel se znakem Z
 2 begin
 3     vrať kód uzlu se znakem Z
 4     UpdateTree(Z)
 5 end
 6 else
 7 begin
 8     vrať kód uzlu NYT
 9     vrať sedmibitový ASCII kód znaku Z
10     UpdateTree(Z)
11 end
```

Pro účely dekomprese je strom implementován jako deterministický konečný automat. Obsahuje `ukazatel`, který udržuje referenci na jeden z uzlů (stav automatu). Na počátku `ukazatel` ukazuje na kořen a s každým přečteným bitem komprimované zprávy se přesune do následujícího uzlu dle přechodové funkce. Je-li přečten kód uzlu obsahujícího znak, je tento znak vrácen a strom aktualizován. Je-li přečten kód uzlu NYT, načte algoritmus dalších 7 bitů, které reprezentují ASCII kód nového znaku, ten je vložen do stromu a vrácen. Zpracování jednoho bitu kódu provádí metoda `PushBit` (viz algoritmus 3).

Při návrhu tohoto algoritmu jsem se snažil o dosažení co nejvyššího kompresního poměru, bohužel jsem tím, ale i díky nevědomosti, absolutně zanedbal správu paměti. Na tento nedostatek mne neupozornily ani jednotkové testy, které nejsou napsané pro řetězce dostatečně dlouhé na to, aby se únik paměti projevil. Algoritmus, tak jak je implementován, má problémy s pamětí i pro menší soubory a není ho tedy dost dobře možné použít při závěrečném porovnávání.

Algoritmus 2: `UpdateTree`

Vstupní parametry: znak `Z`
Výstupní parametry: nemá

```
 1 uzel U := uzel se znakem Z
 2 while uzel U není kořen
 3 begin
 4    if v bloku existuje uzel s vyšším indexem než má uzel U
 5    begin
 6       prohoď uzel U s uzlem s nejvyšším indexem v bloku
 7    end
 8    inkrementuj počet výskytů v uzlu U
 9    U := předek uzlu U
10 end
```

Algoritmus 3: `PushBit`

Vstupní parametry: jeden bit kódu `B`
Výstupní parametry: přečtený znak, byl-li v tomto kroku přečten

```
 1 if čten znak nevyskytující se ve stromě
 2 begin
 3    kumuluj 7 bitů
 4    if nakumulováno 7 bitů
 5    begin
 6       vrať přečtený znak Z
 7       AddChar(Z)
 8       přesměruj ukazatel na kořen
 9    end
10 end
11 else
12 begin
13    dle B přesměruj ukazatel na jeho potomka
14    if ukazatel je uzel obsahující znak
15    begin
16       vrať znak Z v uzlu
17       AddChar(Z)
18       přesměruj ukazatel na kořen
19    end
20    else if ukazatel je uzel NYT
21    begin
22       přesměruj ukazatel na kořen
23       nastav stav stromu na čtení nového znaku
24    end
25 end
```

7.2.2 JSONH

Abych mohl ve staticky typovaném jazyce C# zpracovat libovolná data ve formátu JSON, tedy pracovat s nimi jako s objekty různých typů, využívám typ `dynamic`. Ten umožňuje provést typovou kontrolu až v době běhu (run time), díky čemuž se s JSON v jazyce C# pracuje částečně podobně jako v JavaScriptu.

Kompresní část algoritmu předpokládá, že všechny objekty v poli budou stejného typu. Komprese je závislá na struktuře objektů. Aby bylo dosaženo významného kompresního poměru, měly by objekty mít více atributů s jednoduchými hodnotami typu číslo, řetězec, `true`, `false` nebo `null` než méně atributů se složitými hodnotami typu pole nebo objekt. Metoda `Compress` třídy `JsonH` je popsána v algoritmu 4.

Algoritmus 4: `Compress`

Vstupní parametry: cesta k souboru s JSON
Výstupní parametry: nemá

```
 1 načti JSON
 2 dekóduj JSON a vlož ho do dynamického pole P
 3 z prvního objektu v poli P načti klíče do kolekce K
 4 vytvoř prázdnou kolekci hodnot H
 5 foreach prvek p v poli P
 6 begin
 7    foreach klíč k v kolekci K
 8    begin
 9       serializuj hodnotu pro klíč k v prvku p do kolekce H
10    end
11 end
12 vytvoř dynamické pole D obsahující počet prvků v kolekci K,
    prvky kolekce K a prvky kolekce H
13 serializuj pole D do souboru
```

Dekompresní algoritmus je implementován v metodě `Decompress` třídy `JsonH`. Jeho implementace je velmi jednoduchá, což dosvědčuje i algoritmus 5.

Algoritmus 5: `Decompress`

Vstupní parametry: cesta k souboru s JSON
Výstupní parametry: nemá

```
1 načti JSON
2 dekóduj JSON a vlož ho do dynamického pole P
3 z prvního prvku v poli P načti počet klíčů do proměnné n
4 z následujících n prvků vytvoř šablonu objektu S
5 ze zbývajících prvků vytvoř pole objektů D dle šablony S
6 serializuj pole D do souboru
```

Tento algoritmus je implementován naprosto jinak než `AdaptiveHuffman` a problémy s pamětí netrpí. Mohl jsem ho tedy pro testovací soubory obsahující homogenní kolekce použít při závěrečném porovnávání.

7.2.3 LZ77

Poučen z chyb udělaných při návrhu a vývoji adaptivního Huffmanova kódování jsem upustil od snahy dosáhnout co nejvyššího kompresního poměru a zaměřil se na správu paměti. Zakódovaná i dekódovaná zpráva jsou do soubory ukládány po menších blocích, které mají určenou maximální délku. Data zakódované zprávy jsou z důvodů dekomprese v bloku uvozena počtem použitých bitů.

Třída `LZ77`, která se stará o kompresi i dekompresi, zpracovává postupně jednotlivé bloky. Komprese jednoho bloku je naznačena v algoritmu 6. V případě, že je zpracován celý blok, dojde k načtení následujícího a proces komprese se opakuje. Implementační detaily zachování konzistence mezi načítáním bloků zde neuvádím.

Algoritmus 6: `compressBlock`
Vstupní parametry: blok dat `B` určený ke kompresi **Výstupní parametry:** nemá

`1 while` není dosaženo konce bloku `B`
`2 begin`
`3` najdi nejdelší frázi ve slovníku
`4` zakóduj trojici offset a délka nalezené fráze a další znak z bloku B
`5` posuň okno o počet zakódovaných znaků vpravo
`6 end`

Dekompresní část je v podstatě inverzí ke kompresi. Tak, jak byly při kompresi vytvářeny kódovací trojice, jsou nyní čteny a dekódovány. Rozdílem proti kompresi je, že nové fráze vkládané na konec slovníku je nutné nejprve dekódovat. Stav slovníku je ale v každém kroku shodný.

Kapitola 8

Porovnání účinnosti komprese dat ve formátu XML a JSON

Poslední kapitola této diplomové práce je zaměřena na aplikaci vybraných kompresních mechanismů na data zapsaná ve formátech XML a JSON. Porovnání bylo provedeno na volně dostupných datech pomocí volně dostupných programů a algoritmů. Naměřené výsledky jsou popsány ve druhé části kapitoly.

8.1 Technická parametry testování

8.1.1 Popis zvolených algoritmů

Pro vzájemné porovnání jsem kromě algoritmů LZ77, XMill, JSONH a CJSON, které jsou popsány v částech 4.2, 5.1, 6.1 a 6.2, zvolil i algoritmy LZMA2, PPMd, gzip, které nejsou závislé na formátu dat. Program XMill byl spouštěn s požadovanými parametry z příkazové řádky, algoritmus CJSON byl spouštěn v prohlížečí Google Chrome a mnou implementované algoritmy LZ77 a JSONH byly spouštěny jako konzolová aplikace referencující vytvořenou knihovnu. Zbývající 3 algoritmy implementuje program 7-Zip [13], který umožňuje volbu parametrů komprese, jako jsou velikosti slovníku, slova apod.

LZMA2 Jde o vylepšenou a optimalizovanou verzi LZ77, která využívá range kodéru a Markovových řetězců (viz [7]). Stejně jako LZ77 využívá slovníku, pro který lze uživatelsky zvolit velikost slovníku i slova. Proti ostatním algoritmům alokuje při kompresi podstatně více paměti.

PPMd Tato statistická kompresní metoda pracuje s několika modely zároveň. Modely slouží k výpočtu pravděpodobnosti výskytu následujících znaků, které jsou kódovány aritmetickým kódováním (viz [7]).

gzip Tento algoritmus je postaven na programu Deflate, který kombinuje LZ77 a Huffmanovo kódování. Nejprve jsou pomocí LZ77 odstraněny opakující se fráze a poté je výstup ještě zakódován Huffmanovým kódováním.

8.1.2 Popis testovacích souborů

Testovací data bylo pro účely porovnání nutné získat zapsaná pomocí XML i JSON. Vybraná testovací data jsou volně dostupná ke stažení a to buď přímo ve formátu XML, nebo jako databáze. V prvním případě jsem data transformoval do formátu JSON pomocí frameworku Json.NET [3], ve druhém jsem soubory XML i JSON vytvořil. Velikost souborů je volena tak, aby bylo možné provést transformaci, a struktura dat je pro účely testování v každém souboru jedinečná. U popisu jednotlivých souborů uvádím hloubku zanoření, tzn. počet do sebe vnořených elementů pro XML nebo objektů a polí pro JSON.

base64img Soubor 29 obrázků zakódovaných jako řetězec v soustavě o základu 64 popsaných pomocí tří údajů. Hloubka zanoření: 2.
Zdroj: Testovací soubory přiložené k XMill

dblp Nehomogenní kolekce bibliografických údajů o periodikách z oblasti počítačových věd. Hloubka zanoření: až 6.
Zdroj: Testovací soubory přiložené k XMill

Employees Data z databáze AdventureWorks2008R2 vybraná pomocí příkazu SELECT obsahují 7 převážně textových údajů o 19972 lidech. Hloubka zanoření: 2.
Zdroj: `msftdbprodsamples.codeplex.com/releases/view/93587`

nasa Astronomická data agentury NASA, jde o převážně textová data s údaji o katalozích. Počet elementů 476646, počet atributů: 56317, hloubka zanoření XML: až 8.
Zdroj: `cs.washington.edu/research/xmldatasets/www/repository.html#nasa`

SigmodRecord Bibliografické údaje o článcích ze stránky sigmod.org. Jsou to převážně textová data – název článku, jména autorů atd. Hloubka zanoření: 6.
Zdroj: `dia.uniroma3.it/Araneus/Sigmod/`

8.2 Výsledky testování

Testované algoritmy, které dovolují nastavit parametry, byly spuštěny několikrát pro různé kombinace parametrů. Z naměřených dat bylo vypozorováno, že při zvyšování hodnot parametrů existuje jistá mez, za kterou se velikost zkomprimovaného souboru snižuje již nevýznamně. Přitom však při kompresi platí mezi velikostí parametrů a množstvím spotřebované paměti přímá úměra, hodnoty parametrů je tedy vhodné volit s rozmyslem.

8.2.1 Velikost komprimovaných souborů

V grafech na obrázcích 8.1, 8.2, 8.3, 8.4 a 8.5 jsou uvedeny nejlepší dosažené výsledky komprimace pro jednotlivé soubory a algoritmy. Pro všechny soubory platí, že nejúčinněji je komprimovala metoda PPMd. Naopak pro 4 soubory obsahující JSON podávala nejhorší výsledky metoda CJSON. To je dáno stejně jako v případě metody JSONH tím, že komprimované soubory jsou validní JSON a obsahují pouze jiným způsobem zapsaná původní data. Na obhajobu těchto algoritmů musím uvést, že jejich primární použití je při zpracování dat JavaScriptem a zde hraje validita komprimovaných dat nespornou roli. Pomineme-li algoritmy specializované pro zpracování JSON a mnou implementované LZ77, dosahuje ve většině případů nejhorších anebo druhých nejhorších výsledků pro oba dva

formáty dat metoda gzip kombinující LZ77 a Huffmanovo kódování. Metoda XMill, která využívá ke kompresi jednotlivých vytvořených bloků právě gzip, podávala proměnlivé výsledky: ve dvou případech byla mírně horší než gzip, ve třech naopak výrazně lepší. V žádném případě však nedosáhla nejlepšího výsledku i pro různé volby kompresorů, což je poněkud překvapivé, ale může to být způsobeno nevhodným výběrem testovacích dat, která jsou převážně textová.

Zvláštním případem jsou soubory base64img (viz obrázek 8.1), u kterých nelze pozorovat typicky menší velikost dat v JSON. U těchto souborů bylo dosaženo nejmenšího kompresního poměru, který je zároveň pro všechny algoritmy mimo JSONH a CJSON přibližně konstantní. Tento jev je velice pravděpodobně způsoben obsahem souborů: obrázky zapsanými jako řetězce 64znakové abecedy. Například pro formát JSON zabírají tyto řetězce více než 95 % obsahu souboru, čemuž odpovídá kompresní poměr (viz tabulka 8.1) blízký hodnotě 1.

Na zbývajících čtyřech grafech (obrázky 8.2, 8.3, 8.4 a 8.5) lze pozorovat proměnlivé výsledky jednotlivých algoritmů, což odpovídá rozdílné struktuře dat v souborech a tomu, že každý algoritmus využívá kombinaci jiných kompresních technik.

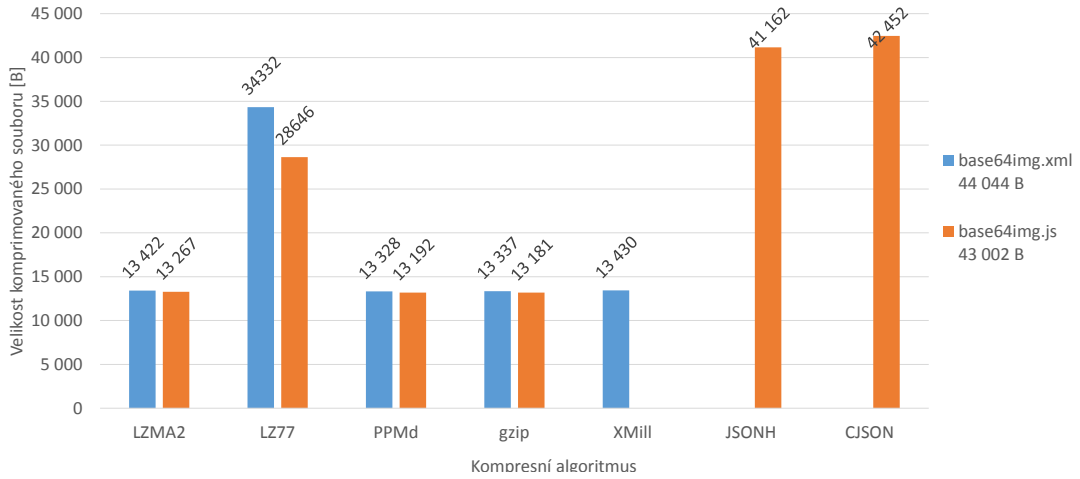

Obrázek 8.1: Velikost komprimovaných souborů base64img.xml a base64img.js

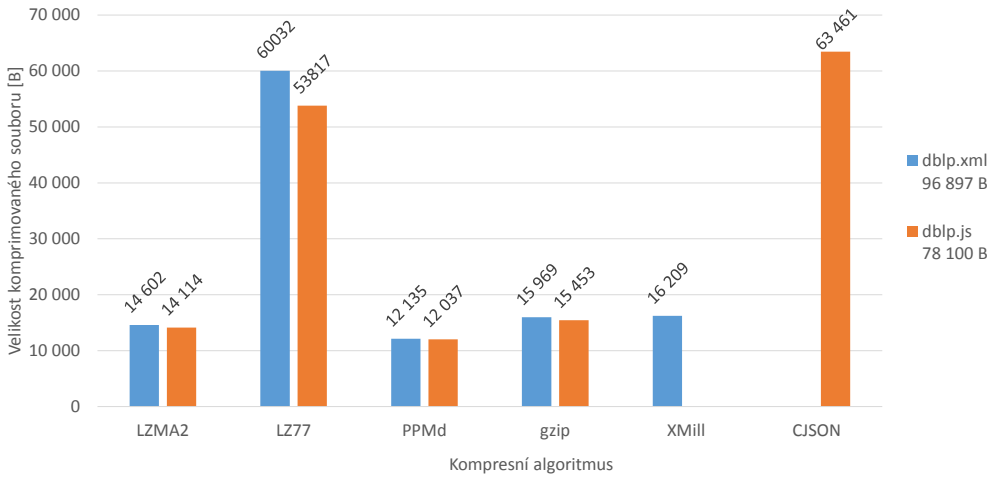

Obrázek 8.2: Velikost komprimovaných souborů dblp.xml a dblp.js

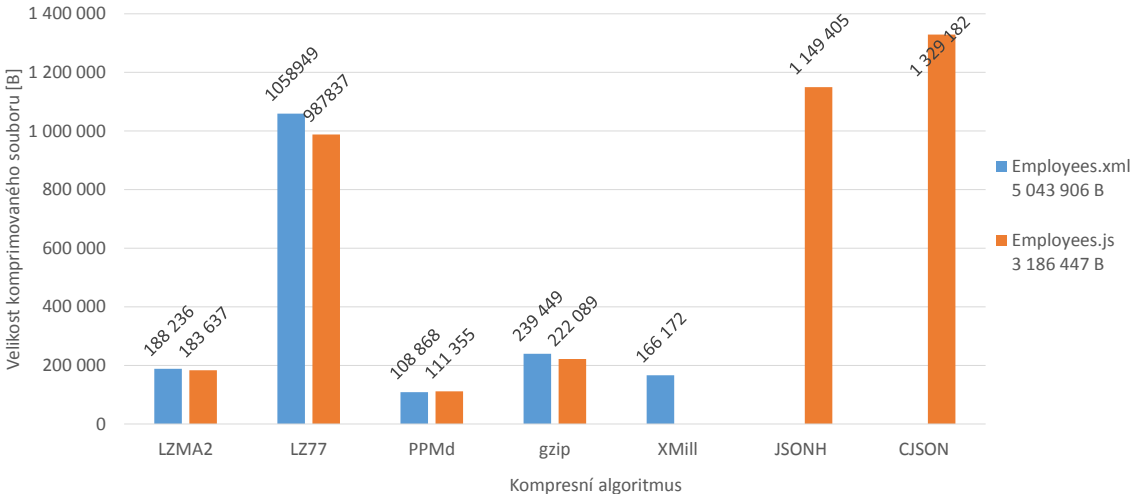

Obrázek 8.3: Velikost komprimovaných souborů Employees.xml a Employees.js

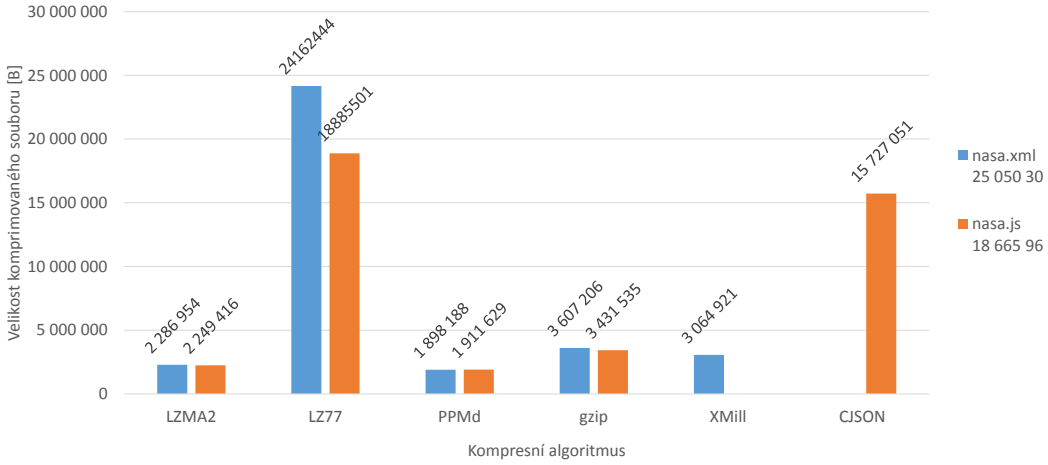

Obrázek 8.4: Velikost komprimovaných souborů nasa.xml a nasa.js

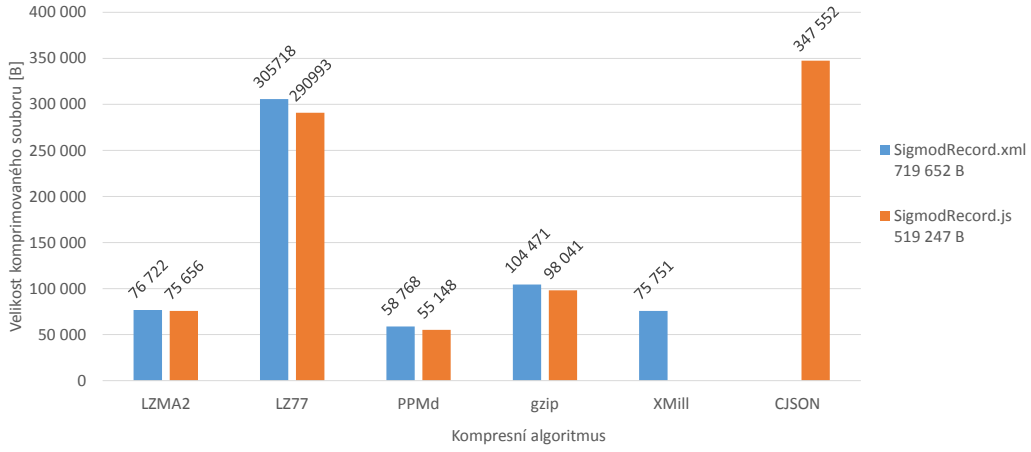

Obrázek 8.5: Velikost komprimovaných souborů SigmodRecord.xml a SigmodRecord.js

8.2.2 Kompresní poměr

V tabulce 8.1 jsou uvedeny nejvyšší získané kompresní poměry pro soubor a kompresní metodu. Pro soubor Employees.xml dosáhly všechny použité metody vysokého kompresního poměru, z nichž nejvyššího 46,33 dosáhla metoda PPMd, tato hodnota odpovídá téměř 98% úspoře místa. Nižší kompresní poměr souborů JSON než jejich XML alternativ je dán nižší redundancí formátu JSON.

Soubor	Kompresní poměr algoritmu						
	LZMA2	LZ77	PPMd	gzip	XMill	JSONH	CJSON
base64img.xml	3,28	1,28	3,30	3,30	3,28		
base64img.js	3,24	1,50	3,26	3,26		1,04	1,01
dblp.xml	6,63	1,61	7,98	6,07	5,97		
dblp.js	5,53	1,45	6,49	5,30			1,23
Employees.xml	26,80	4,76	46,33	21,06	30,35		
Employees.js	17,35	3,23	28,62	14,35		2,77	2,40
nasa.xml	10,95	1,33	13,20	6,94	8,17		
nasa.js	8,30	0,77	9,76	5,44			1,17
SigmodRecord.xml	9,38	2,35	12,26	6,89	9,50		
SigmodRecord.js	6,87	1,78	9,42	5,30			1,49

Tabulka 8.1: Kompresní poměr vybraných algoritmů na testovacích souborech

8.2.3 Hodnocení algoritmu LZ77

Testování vlastní implementace LZ77 nepřineslo příliš dobré výsledky. V měřených charakteristikách končí daleko za ostatními obecnými algoritmy. Pro soubor nasa.js dosáhl dokonce kompresního poměru menšího než 1, tedy došlo k nárůstu objemu dat. Přitom při kompresi tohoto souboru dosáhly ostatní algoritmy nadprůměrného výsledku. Další jeho nepříjemnou vlastností je dlouho trvající proces komprese a ještě déle trvající proces dekomprese.

Za nejpravděpodobnější příčinu považuji malou velikost slovníku a příliš častý zápis malého množství dat do souboru. Ke zvolenému nastavení jsem ale dospěl ve snaze vyvarovat se nadměrné spotřeby paměti, což se podařilo. Vzhledem k tomu, že smyslem práce nebylo vytvořit dokonalý kompresní algoritmus, ale spíše si prakticky vyzkoušet danou problematiku, považuji dosažené výsledky za uspokojivé.

8.2.4 Porovnání výsledků

Srovnáváme-li soubory po dvojicích, tedy vždy XML a JSON obsahující stejná data, lze pozorovat jisté trendy. Prvním z nich je, že soubor s JSON je vždy menší než soubor s XML. To je dáno tím, jak již bylo napsáno v kapitole 1, že JSON vznikl jako odlehčená alternativa ke XML a tedy neobsahuje tolik redundance. Dalším zajímavým pozorováním je, že ač se testovací soubory obsahující stejná data v XML a JSON liší významně velikostí, tak zkomprimované soubory mají přibližně stejnou velikost.

Účinnost kompresních algoritmů pro obecná data je velmi vysoká pro oba zkoumané formáty. Metoda PPMd dokonce algoritmy využívající znalosti struktury dat značně překonává. Pokud bychom se zajímali pouze o velikost komprimovaných souborů, potažmo

kompresní poměr, nelze ke kompresi doporučit specializované algoritmy popsané v kapitolách 5 a 6. Pokud ale potřebujeme s komprimovanými daty pracovat (např. dotazování do zkomprimovaných dat, viz 5.2), nezbývá nám, než tyto specializované algoritmy použít. Je to ale vykoupeno nižším kompresním poměrem.

Rozhodnutí, zda je výhodnější komprimovat data ve formátu XML nebo JSON, není tak jednoznačné, jak jsem na začátku práce předpokládal. V porovnání původních souborů jsou jasně menší soubory JSON, zatímco komprimované testovací soubory se velikostí liší v řádu jednotek procent. Výhodnost využití znalosti struktury dat se nepodařilo prokázat. Na základě uvedených poznatků považuji za úspornější, tzn. vhodnější k archivaci a přenosu dat, formát JSON.

Závěr

Tato závěrečná diplomová práce se věnuje kompresi dat a to hlavně kompresi s využitím znalosti struktury dat. Porovnávány jsou vzájemně datové formáty XML a JSON s cílem určit, který z nich je vhodnější ke kompresi a tím úspornější při archivaci či přenosu dat.

XML je redundantní textový formát, který byl navržen tak, aby byl snadno čitelný pro člověka. Této redundance lze při kompresi XML souboru využít. Formát JSON vznikl jako úsporná alternativa právě ke XML s myšlenkou odstranění redundance dané definicí syntaxe XML. Oba formáty se dnes velice často využívají v prostředí internetu pro práci s daty a proto je vhodné vědět, jaké úspory může jejich komprese přinést.

Praktická část práce je složena ze dvou úkolů. V prvním byla implementována kompresní knihovna, která obsahuje tři algoritmy. Algoritmy Huffmanovo kódování a LZ77 byly zvoleny zejména z toho důvodu, že je úspěšně kombinují algoritmy LZMA2 a gzip, který navíc ke kompresi souborů XML využívá algoritmus XMill. Důležitým poznatkem je, že nejsložitější na implementaci kompresního algoritmu je dosažení dostatečné rychlosti zpracování dat a vysoké efektivity při správě paměti. V tomto směru je na tuto diplomovou práci možné navázat a rozšířit ji o náměty, které se do jejího obsahu nepodařilo zapracovat.

Dalším praktickým úkolem bylo porovnat účinky komprese dat zapsaných ve formátech XML a JSON pomocí různých kompresních technik. Zvolené algoritmy LZMA2, LZ77, PPMd, gzip, XMILL, JSONH a CJSON byly použity ke komprimaci pěti souborů obsahujících XML a JSON. Tyto soubory byly voleny tak, aby nebyly navzájem podobné velikostí a strukturou dat. Naměřené výsledky jsou v podobě grafů a tabulky popsány v kapitole 8. Z naměřených dat vyplývá, že moderní kompresní metody, jako jsou LZMA2 a PPMd, dokážou komprimovat XML i JSON se srovnatelnou nebo dokonce vyšší účinností než algoritmy specializované. Algoritmy JSONH a CJSON dosáhly nejhorších výsledků pro úplně všechny testovací soubory, což je ale dáno naprosto rozdílným způsobem komprimace.

Mezi soubory XML a JSON obsahující stejná data je možné pozorovat významný rozdíl ve velikosti ve prospěch formátu JSON. Toto ale neplatí pro soubory po komprimaci, kdy je rozdíl ve velikosti podstatně menší. Pokud uživatel nevyžaduje možnost práce s komprimovanými daty, lze doporučit použití klasických běžně dostupných kompresních algoritmů. Na základě výše zmíněných poznatků považuji formát JSON za vhodnější ke kompresi a práci s daty.

Seznam použitých zdrojů

[1] GIAMMARCHI, Andrea. *JSONH: JSON Homogeneous Collections Compressor* [online]. 2014 [cit. 2015-03-17]. Dostupné na: <https://github.com/WebReflection/JSONH>

[2] HANOV, Steve. Compress your JSON with automatic type extraction. *Steve Hanov's Blog* [online]. 2011 [cit. 2015-03-17]. Dostupné z: <http://stevehanov.ca/blog/index.php?id=104>

[3] Json.NET - Newtonsoft. *Json.NET - Newtonsoft* [online]. 2015-01-11 [cit. 2015-04-05]. Dostupné na: http://www.newtonsoft.com/json

[4] LIEFKE, Hartmut; SUCIU, Dan. XMill: an Efficient Compressor for XML Data. *Proceedings of the 2000 ACM SIGMOD international conference on Management of data - SIGMOD '00*. 2000, s. 153-164. DOI: 10.1145/342009.335405.

[5] MAREŠ, Jan. *Teorie kódování.* 1. vyd. Praha: Česká technika, 2008. 120 s. ISBN 978-80-01-04203-8.

[6] SALOMON, David. *Data Compression: the complete reference.* 4th ed. London: Springer, 2007, xxv, 1092 s. ISBN 978-1-84628-602-5.

[7] SAYOOD, Khalid. *Introduction to data compression: the complete reference.* 4th ed. Waltham, MA: Morgan Kaufmann, c2012, xvi, 740 s. ISBN 978-0-12-415796-5.

[8] Standard ECMA-404. *The JSON Data Interchange Format.* Geneva: Ecma International, 2013, [online], [cit. 28. října 2014]. Dostupné na: <http://www.ecma-international.org/publications/files/ECMA-ST/ECMA-404.pdf>.

[9] The Digital Universe of Opportunities: Rich Data and the Increasing Value of the Internet of Things. INTERNATIONAL DATA CORPORATION. *EMC* [online]. 2014 [cit. 2015-02-25]. Dostupné z: <http://www.emc.com/leadership/digital-universe/2014iview/executive-summary.htm>.

[10] TOLANI, P. M.; Haritsa, J. R. XGRIND: A Query-friendly XML Compressor. *Proceedings of the 18th International Conference on Data Engineering - ICDE '02*. 2002, s. 225–234

[11] VAJDA, Igor. *Teorie informace.* Vyd. 1. Praha: Vydavatelství ČVUT, 2004. 109 s. ISBN 80-01-02986-7.

[12] W3C. *Extensible Markup Language (XML) 1.0 (Fifth Edition).* 26. listopadu 2008, [online], [cit. 26. listopadu 2014]. Dostupné na: <http://www.w3.org/TR/2008/REC-xml-20081126/>.

[13] *7-Zip* [online]. 2010-11-18 [cit. 2015-04-07]. Dostupné na: http://www.7-zip.org

Přílohy

Příloha A

Název/obsah přílohy

A.1 Porovnání XML a JSON

XML

```
<widget>
 <debug>on</debug>
 <window
  title="Sample Widget">
  <name>main_window</name>
  <width>500</width>
  <height>500</height>
 </window>
 <image
  src="Images/Sun.png"
  name="sun1">
  <hOffset>250</hOffset>
  <vOffset>250</vOffset>
  <alignment>center</alignment>
 </image>
 <text
  data="Click Here"
  size="36"
  style="bold">
  <name>text1</name>
  <hOffset>250</hOffset>
  <vOffset>100</vOffset>
  <alignment>center</alignment>
  <onMouseUp>sun1.opacity =
   (sun1.opacity / 100) * 90;
  </onMouseUp>
 </text>
</widget>
```

JSON

```
{ "widget": {
 "debug": "on",
 "window": {
  "title": "Sample Widget",
  "name": "main_window",
  "width": 500,
  "height": 500
 },
 "image": {
  "src": "Images/Sun.png",
  "name": "sun1",
  "hOffset": 250,
  "vOffset": 250,
  "alignment": "center"
 },
 "text": {
  "data": "Click Here",
  "size": 36,
  "style": "bold",
  "name": "text1",
  "hOffset": 250,
  "vOffset": 100,
  "alignment": "center",
  "onMouseUp": "sun1.opacity =
   (sun1.opacity / 100) * 90;"

 }
}}
```